


SKRIPSI

**METODE *GENERAL REGRESSION NEURAL NETWORK* (GRNN)
UNTUK MEMPREDIKSI INDEKS SAHAM**

***GENERAL REGRESSION NEURAL NETWORK (GRNN) METHOD TO
PREDICT STOCK INDEX***



Nabila Mutiara Suci

19/445721/PA/19545

**PROGRAM STUDI STATISTIKA
DEPARTEMEN MATEMATIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS GADJAH MADA
YOGYAKARTA**


2023

SKRIPSI

**METODE *GENERAL REGRESSION NEURAL NETWORK* (GRNN)
UNTUK MEMPREDIKSI INDEKS SAHAM**

***GENERAL REGRESSION NEURAL NETWORK (GRNN) METHOD TO
PREDICT STOCK INDEX***

Diajukan untuk memenuhi salah satu syarat memperoleh derajat
Sarjana Sains Statistika



Nabila Mutiara Suci

19/445721/PA/19545

**PROGRAM STUDI STATISTIKA
DEPARTEMEN MATEMATIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS GADJAH MADA
YOGYAKARTA**

2023

HALAMAN PENGESAHAN

SKRIPSI

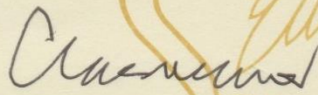
METODE *GENERAL REGRESSION NEURAL NETWORK* (GRNN) UNTUK MEMPREDIKSI INDEKS SAHAM

Telah dipersiapkan dan disusun oleh

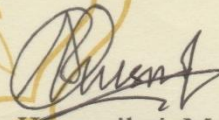
NABILA MUTIARA SUCI
19/445721/PA/19545

Telah dipertahankan di depan Tim Penguji
pada tanggal 21 Juni 2023

Susunan Tim Penguji



Dr. Abdurakhman, S.Si., M.Si.
Pembimbing

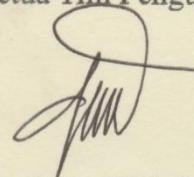


Atina Husnaqilati, M.Sc., Ph.D.
Ketua Tim Penguji

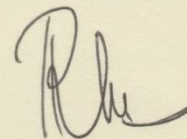
Mengetahui,
a.n. Dekan FMIPA UGM
Wakil Dekan Bidang Pendidikan, Pengajaran
dan Kemahasiswaan



Prof. Drs. Roto, M.Eng., Ph.D.
NIP. 196711171993031020



Era Setya Cahyati, S.Si., M.Sc.
Penguji



Mohamad Fahruli Wahyujati, S.Si., M.Si.
Penguji

PERNYATAAN

Saya yang bertanda tangan di bawah ini:

Nama : Nabila Mutiara Suci
NIM : 19/445721/PA/19545
Tahun terdaftar : 2019
Program Studi : Statistika
Fakultas/Sekolah : Matematika dan Ilmu Pengetahuan Alam

Menyatakan bahwa Laporan Tugas Akhir Skripsi ini tidak terdapat karya yang pernah diajukan untuk memperoleh gelar kesarjanaan di suatu Perguruan Tinggi, dan sepanjang sepengetahuan saya juga tidak terdapat karya atau pendapat yang pernah ditulis atau diterbitkan oleh orang lain, kecuali yang secara tertulis diacu dalam naskah ini dan disebutkan dalam daftar pustaka.

Dengan ini saya menyatakan bahwa Laporan Tugas Akhir Skripsi ini bebas dari unsur-unsur plagiasi dan apabila Laporan Tugas Akhir Skripsi ini di kemudian hari terbukti merupakan plagiasi dari hasil karya penulis lain dan/atau dengan sengaja mengajukan karya atau pendapat yang merupakan hasil karya penulis lain, maka penulis bersedia menerima sanksi akademik dan/atau sanksi hukum yang berlaku.

Yogyakarta, 15 Juni 2023



Nabila Mutiara Suci
19/445721/PA/19545

HALAMAN MOTO DAN PERSEMBAHAN

MOTO

“Dan Dia bersama kamu di mana saja kamu berada.”

Quran 57:4

“Create your own happiness.”

Anonymous

PERSEMBAHAN

*Karya ini penulis persembahkan untuk
diri sendiri, papa, mama, dan adik-adik.*

KATA PENGANTAR

Puji syukur kehadiran Allah SWT yang telah memberikan rahmat-Nya sehingga penulis dapat menyelesaikan tugas akhir skripsi ini yang berjudul “METODE *GENERAL REGRESSION NEURAL NETWORK* (GRNN) UNTUK MEMPREDIKSI INDEKS SAHAM”. Skripsi ini disusun untuk menyelesaikan derajat pendidikan S1 Program Studi Statistika, Fakultas Matematika dan Ilmu Pengetahuan Alam, Universitas Gadjah Mada.

Dalam pengerjaan skripsi ini, tentunya penulis mendapat bimbingan, dukungan, dan bantuan dari berbagai pihak. Oleh karena itu, penulis ingin menyampaikan terima kasih kepada:

1. Bapak Prof. Dr.Eng. Kuwat Triyana, M.Si. selaku Dekan Fakultas Matematika dan Ilmu Pengetahuan Alam Universitas Gadjah Mada.
2. Bapak Dr. Nanang Susyanto, S.Si., M.Sc., selaku Ketua Departemen Matematika Fakultas Matematika dan Ilmu Pengetahuan Alam Universitas Gadjah Mada.
3. Bapak Prof. Dr.rer.nat. Dedi Rosadi, S.Si., M.Sc., selaku Ketua Program Studi S1 Statistika Fakultas Matematika dan Ilmu Pengetahuan Alam Universitas Gadjah Mada.
4. Bapak Dr. Abdurakhman, S.Si., M.Si., selaku Dosen Pembimbing Tugas Akhir penulis yang telah memberikan arahan, bimbingan, masukan, serta dukungan kepada penulis dalam menyelesaikan skripsi ini.
5. Almh. Ibu Dr. Herni Utami, S.Si., M.Si. dan Bapak Drs. Danardono, MPH., Ph.D., selaku Dosen Pembimbing Akademik penulis yang telah membantu penulis selama perkuliahan di Program Studi Statistika Fakultas Matematika dan Ilmu Pengetahuan Alam Universitas Gadjah Mada.
6. Seluruh dosen Program Studi S1 Statistika Universitas Gadjah Mada yang telah memberikan ilmu kepada penulis selama masa kuliah.
7. Papa, Mama, adik-adik, dan keluarga penulis yang telah mendukung dan menyertakan doa sejak awal hingga akhir.

8. Teman-teman penulis dari Statistika UGM, terutama angkatan 2019 yang telah bersama-sama berjuang selama perkuliahan.
9. Teman-teman dan pihak lain yang telah memberikan dukungan kepada penulis tanpa dapat penulis sebutkan satu-persatu.

Penulis menyadari bahwa skripsi ini masih jauh dari kesempurnaan. Oleh karena itu, diharapkan kritik dan saran sehingga dapat dijadikan bahan evaluasi bagi penulis. Penulis mengucapkan terima kasih dan memohon maaf atas kesalahan dalam penulisan skripsi ini. Semoga skripsi ini dapat memiliki manfaat bagi berbagai pihak.

Yogyakarta, 15 Juni 2023

Penulis

DAFTAR ISI

HALAMAN JUDUL.....	i
HALAMAN PENGESAHAN.....	ii
PERNYATAAN.....	iii
HALAMAN MOTO DAN PERSEMBAHAN	iv
KATA PENGANTAR.....	v
DAFTAR ISI	vii
DAFTAR TABEL.....	x
DAFTAR GAMBAR	xi
DAFTAR LAMPIRAN	xii
INTISARI.....	xiii
ABSTRACT.....	xiv
BAB I PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Batasan Masalah.....	3
1.3 Tujuan Penelitian.....	4
1.4 Tinjauan Pustaka.....	4
1.5 Metode Penelitian.....	5
1.6 Sistematika Penulisan.....	6
BAB II LANDASAN TEORI	8
2.1 Peramalan	8
2.1.1 Pengertian Peramalan.....	8
2.1.2 Jenis-jenis Peramalan	8

2.2	Data <i>Time Series</i>	11
2.2.1	Pengertian Data <i>Time Series</i>	11
2.2.2	Jenis-Jenis Pola Data <i>Time Series</i>	11
2.2.3	Jenis-Jenis Metode <i>Time Series</i>	12
2.3	Jaringan Saraf Tiruan.....	13
2.3.1	Jenis-Jenis Jaringan Saraf Tiruan	14
2.3.2	Arsitektur Jaringan Saraf Tiruan	15
2.4	Norma Euclidean	17
2.5	Jaringan Radial Basis	18
2.6	Fungsi Aktivasi.....	18
2.7	Regresi Kernel	20
2.8	Ukuran Ketepatan Nilai Peramalan	21
2.9	Model <i>Autoregressive</i> (AR) dan <i>Moving Average</i> (MA).....	22
2.10	Fungsi Autokorelasi Parsial (PACF)	24
2.11	Uji Korelasi	25
2.12	Indeks Harga Saham.....	27
2.13	Indeks Saham Syariah Indonesia.....	29
2.14	Faktor Makroekonomi	29
BAB III <i>GENERAL REGRESSION NEURAL NETWORK</i>		31
3.1	Pembagian Data.....	32
3.2	Normalisasi dan Denormalisasi Data	33
3.3	Pemilihan Parameter <i>Smoothing</i>	33
3.4	Struktur dan Arsitektur GRNN.....	34
3.5	Proses Prediksi dengan GRNN.....	36

BAB IV STUDI KASUS	38
4.1 Deskripsi Data	38
4.2 Uji Korelasi	40
4.3 Identifikasi Input	43
4.4 Pembagian Data.....	44
4.5 Normalisasi Data	45
4.6 GRNN dengan Input Data Masa Lalu	45
4.7 GRNN dengan Input Kurs Jual, Kurs Beli, dan Inflasi	48
4.8 Perbandingan	50
4.9 Prediksi untuk Empat Periode Ke Depan	52
BAB V PENUTUP.....	56
5.1 Kesimpulan.....	56
5.2 Saran	57
DAFTAR PUSTAKA	58
LAMPIRAN.....	61

DAFTAR TABEL

Tabel 4.1 Statistik dasar data.....	38
Tabel 4.2 Uji korelasi variabel output dan variabel-variabel input	43
Tabel 4.3 <i>Partial Autocorrelation Function</i> harga terakhir ISSI	44
Tabel 4.4 Pembagian data	44
Tabel 4.5 Hasil percobaan <i>spread</i> input masa lalu	46
Tabel 4.6 Hasil prediksi data <i>test</i> input data masa lalu	46
Tabel 4.7 Hasil percobaan <i>spread</i> input kurs jual, kurs beli, dan inflasi	48
Tabel 4.8 Hasil prediksi data <i>test</i> input kurs jual, kurs beli, dan inflasi.....	49
Tabel 4.9 Uji kesalahan prediksi	50
Tabel 4.10 Hasil prediksi dengan input data masa lalu	53
Tabel 4.11 Hasil prediksi dengan input kurs jual, kurs beli, dan inflasi	55

DAFTAR GAMBAR

Gambar 2.1 Pola data runtun waktu	12
Gambar 2.2 Jaringan saraf tiruan lapisan tunggal	15
Gambar 2.3 Jaringan saraf tiruan multilapis	16
Gambar 2.4 Jaringan saraf tiruan lapisan kompetitif	17
Gambar 2.5 Fungsi identitas	19
Gambar 2.6 Fungsi biner dengan ambang batas	19
Gambar 2.7 Fungsi biner sigmoid dengan $\sigma = 1$ dan $\sigma = 3$	20
Gambar 2.8 Fungsi sigmoid bipolar	20
Gambar 3.1 Arsitektur GRNN	34
Gambar 3.2 Tahapan prediksi dengan GRNN	37
Gambar 4.1 Plot <i>time series</i> data (a) harga ISSI, (b) kurs jual, (c) kurs beli, dan (d) inflasi	39
Gambar 4.2 <i>Scatterplot</i> hubungan harga terakhir ISSI dan kurs jual	40
Gambar 4.3 <i>Scatterplot</i> hubungan harga terakhir ISSI dan kurs beli	41
Gambar 4.4 <i>Scatterplot</i> hubungan harga terakhir ISSI dan inflasi	42
Gambar 4.5 Plot <i>Partial Autocorrelation Function</i> (PACF)	43
Gambar 4.6 Perbandingan harga aktual dan prediksi menggunakan input masa lalu	47
Gambar 4.7 Plot perbandingan harga aktual dan prediksi menggunakan input kurs jual, kurs beli, dan inflasi	50
Gambar 4.8 Plot perbandingan harga aktual dan prediksi	51

DAFTAR LAMPIRAN

Lampiran 1. Data harga terakhir Indeks Saham Syariah Indonesia dan Kurs	61
Lampiran 2. Data inflasi.....	72
Lampiran 3. Syntax Python.....	73
Lampiran 4. Hasil normalisasi data pelatihan	83
Lampiran 5. Hasil normalisasi data pengujian	84
Lampiran 6. Hasil prediksi data testing input data masa lalu	85
Lampiran 7. Input prediksi dengan input faktor makroekonomi	88

INTISARI

METODE *GENERAL REGRESSION NEURAL NETWORK* (GRNN) UNTUK MEMPREDIKSI INDEKS SAHAM

Oleh

Nabila Mutiara Suci

19/445721/PA/19545

Investasi saham syariah di Indonesia sudah banyak diminati masyarakat, karena dapat selalu mengikuti syariat Islam. Dalam berinvestasi, indeks saham merupakan salah satu hal yang penting untuk diperhatikan. Dengan indeks saham, para investor dapat melihat pergerakan harga, apakah meningkat atau menurun, untuk menjadi acuan dalam mengukur keuntungan dan langkah ke depan yang perlu diambil saat berinvestasi. Salah satu indeks saham adalah Indeks Saham Syariah Indonesia (ISSI), dimana indeks ini digunakan untuk mengawasi seluruh saham-saham syariah di pasar modal. Untuk dapat mengetahui pergerakan harga saham syariah, investor perlu melakukan prediksi pada Indeks Saham Syariah Indonesia. Pada skripsi ini, peramalan atau prediksi dilakukan dengan menggunakan salah satu metode *neural network*, yaitu *General Regression Neural Network* (GRNN). Input untuk melakukan peramalan adalah harga masa lalu dari ISSI dan ditambah dengan faktor makroekonomi, seperti kurs jual, kurs beli, dan inflasi. Dari kedua input tersebut, hasil yang didapatkan adalah peramalan GRNN dengan menggunakan data masa lalu lebih baik untuk digunakan karena memiliki nilai kesalahan prediksi yang lebih rendah dibandingkan menggunakan faktor makroekonomi.

Kata kunci: *General Regression Neural Network* (GRNN), Indeks Saham Syariah Indonesia (ISSI), *Neural Network*, Peramalan.

ABSTRACT

GENERAL REGRESSION NEURAL NETWORK (GRNN) METHOD TO PREDICT STOCK INDEX

By

Nabila Mutiara Suci

19/445721/PA/19545

Sharia stock investment in Indonesia has been in great demand by the public, because it can follow Islamic law. In investing, the stock index is one of the important things to note. With a stock index, the investors can see the price movements, whether increasing or decreasing, to become a reference in measuring the profits and future steps that need to be taken when investing. One of the sharia index is Indonesia Sharia Stock Index (ISSI), which this index is used for observe the whole sharia stocks in capital market. When the investors want to see the price movement of sharia stock, they need to predict the index. In this research, forecasting or predicting is using one of the neural network method, specifically General Regression Neural Network (GRNN). The input that is used for forecasting are past data of ISSI and macroeconomic factors, such as selling rate, buying rate, and inflation. The result from both inputs is GRNN forecasting with past data of ISSI is better to used because it has prediction error values smaller than using macroeconomic factors.

Keywords: General Regression Neural Network (GRNN), Indonesia Sharia Stock Index (ISSI), Neural Network, Forecasting.

BAB I

PENDAHULUAN

1.1 Latar Belakang

Investasi sudah menjadi salah satu kegiatan yang banyak dilakukan oleh masyarakat Indonesia dalam mengembangkan pemikiran bahwa investasi merupakan hal yang penting untuk mempersiapkan diri di kemudian hari dengan perolehan *passive income*. Investasi sendiri dapat berupa aset riil, seperti emas, tanah, atau bangunan, dan juga investasi dalam surat-surat berharga atau sekuritas. Saham merupakan salah satu jenis surat berharga yang diminati oleh masyarakat, dimana pergerakan harga saham diukur oleh indeks saham yang ada di pasar modal.

Pasar modal merupakan suatu tempat yang memfasilitasi pertemuan antara pihak yang memiliki dana dan pihak yang membutuhkan dana secara langsung maupun tidak langsung. Dalam hal ini, pihak yang memiliki dana disebut dengan investor dan pihak yang membutuhkan dana disebut emiten dengan fungsi antara lain menjadi sarana penambah modal usaha, yaitu dengan cara menjual saham (Muklis, 2016). Selain memiliki pasar modal untuk saham-saham konvensional, pasar modal di Indonesia juga memiliki pasar modal syariah. Dengan mayoritas masyarakat yang beragama Islam, maka pasar modal syariah diperlukan untuk masyarakat yang ingin melakukan investasi yang sesuai dengan ketentuan syariat Islam. Menurut Peraturan Otoritas Jasa Keuangan (2015), kegiatan atau usaha yang tidak berdasarkan prinsip syariah dalam pasar modal, antara lain perusahaan yang berada di bidang jasa keuangan riba, perjudian, jual beli risiko dengan unsur ketidakpastian, atau perusahaan yang memproduksi hal yang diharamkan. Transaksi-transaksi di pasar modal syariah diperbolehkan asalkan tidak melanggar ketentuan-ketentuan syariat yang berlaku.

Pasar modal syariah di Indonesia memiliki beberapa indeks saham. Indeks saham merupakan suatu indikator tren pasar untuk mengetahui kondisi pasar saat meningkat ataupun saat menurun (Junaidi, Wibowo, & Hasni, 2021). Indeks saham pada pasar modal syariah di Indonesia diawali dengan Jakarta Islamic

Index (JII) pada tahun 2000, Indeks Saham Syariah Indonesia (ISSI) yang diluncurkan pada tahun 2011, Jakarta Islamic Index 70 (JII70) pada tahun 2018, dan IDX-MES BUMN 17 pada tahun 2021.

Indeks Saham Syariah Indonesia (ISSI) merupakan salah satu indeks harga saham di Indonesia yang diluncurkan pada 12 Mei 2011. Indeks saham ini mencakup seluruh saham-saham syariah yang terdaftar pada papan utama dan pengembangan di Bursa Efek Indonesia (BEI) serta masuk ke dalam Daftar Efek Syariah (DES) yang diterbitkan oleh Otoritas Jasa Keuangan (OJK). Saham-saham yang ada di ISSI jumlahnya lebih banyak daripada indeks saham syariah lainnya. Konstituen dari ISSI perlu diseleksi sebanyak dua kali dalam setahun, dengan mengikuti jadwal *review* dari DES. ISSI berfungsi untuk menjadi sarana dalam memudahkan serta menarik investor dalam memilih investasi di pasar modal yang sering diragukan kehalalannya (Pasaribu & Firdaus, 2013). Harga penutupan tertinggi dari ISSI pernah menyentuh Rp222.00 pada tanggal 27 Desember 2022 sepanjang waktu indeks ini berada di pasar modal Indonesia.

Saham syariah pada masa sekarang sedang digemari di Indonesia. Tercatat dari Kinerja Pasar Modal Syariah yang dikeluarkan BEI (Bursa Efek Indonesia, 2021, 2022), pada tahun 2021, jumlah investor saham syariah di Indonesia sudah mencapai 105,174 orang dan per bulan Desember 2022, jumlah investor naik menjadi 117,942 orang dengan total nilai transaksi mencapai 10.1 triliun rupiah. Hal ini menunjukkan bahwa saham syariah juga tidak kalah diminati oleh masyarakat Indonesia dalam berinvestasi secara aman.

Indeks saham syariah tentunya terus mengalami kenaikan atau penurunan, seperti disebabkan oleh banyaknya aktivitas ekonomi atau dipengaruhi variabel makroekonomi dan moneter di Indonesia (Sjahrir, 1995). Inflasi dan nilai tukar rupiah (kurs) memiliki pengaruh terhadap Indeks Saham Syariah Indonesia (Junaidi et al., 2021; Suciningtias & Khoiroh, 2015). Dengan ini, investor perlu melakukan analisis untuk dapat memprediksi ISSI sebagai acuan dalam melakukan investasi saham syariah di masa yang akan datang, sehingga investor dapat mengetahui langkah apa yang perlu dilakukan untuk berinvestasi pada saham-saham syariah yang ada di Indonesia.

Peramalan merupakan suatu kegiatan dalam melakukan prediksi atau meramalkan hal yang akan terjadi di masa depan dengan hasil yang seakurat mungkin. Peramalan dapat menggunakan data masa lalu untuk mengetahui sesuatu di masa depan dan juga dapat menggunakan variabel lain di luar data tersebut. Salah satu metode yang dapat digunakan untuk melakukan perhitungan peramalan adalah dengan *General Regression Neural Network* (GRNN). Metode ini dikembangkan oleh Specht dan merupakan salah satu algoritma *neural network* yang didasarkan pada teori regresi nonlinear (*kernel*). GRNN sudah banyak digunakan untuk melakukan peramalan atau prediksi pada berbagai masalah. GRNN akan menggunakan data *training* untuk mencari pola sehingga dapat menghasilkan *output* yang baik ketika digunakan pada data *test*.

Dengan ini, penulis ingin melakukan prediksi terkait Indeks Saham Syariah Indonesia menggunakan salah satu metode *neural network*, yaitu General Regression Neural Network (GRNN). Input yang akan digunakan untuk memprediksi merupakan dua input, yaitu data masa lalu dari ISSI dan ditambah juga dengan faktor makroekonomi, yaitu kurs jual, kurs beli, dan inflasi.

1.2 Batasan Masalah

Pembatasan masalah dalam penelitian ini dilakukan untuk menjaga kesimpulan agar dapat tetap pada tujuan penelitian dan menjamin bahwa permasalahan terselesaikan dengan baik. Pada skripsi ini terdapat pembatasan pada data runtun waktu untuk dilakukan peramalan menggunakan metode *General Regression Neural Network* (GRNN). Data runtun waktu yang digunakan adalah data Indeks Saham Syariah Indonesia (ISSI) yang diambil dari situs daring <https://id.investing.com> dan untuk data kurs jual, kurs beli, dan inflasi diambil dari situs daring resmi dari Bank Indonesia. Pengukuran nilai kesalahan prediksi dilakukan dengan menggunakan *Mean Absolute Error* (MAE) dan *Root Mean Squared Error* (RMSE), kemudian dilakukan perbandingan nilai kesalahan prediksi pada input data masa lalu dan input yang ditambah kurs jual, kurs beli, dan inflasi.

1.3 Tujuan Penelitian

Tujuan dalam penelitian ini antara lain:

1. Dapat mengetahui tingkat keakuratan atau nilai kesalahan hasil prediksi harga penutupan ISSI menggunakan metode *General Regression Neural Network* (GRNN) pada input data masa lalu serta input kurs jual, kurs beli, dan inflasi.
2. Dapat mengetahui input terbaik untuk digunakan dalam melakukan peramalan Indeks Saham Syariah Indonesia (ISSI) dengan metode GRNN.
3. Dapat menerapkan metode GRNN dalam menghasilkan hasil prediksi dari harga penutupan ISSI untuk beberapa periode ke depan.

1.4 Tinjauan Pustaka

Leung, Chen, dan Daouk (2000) meramalkan nilai tukar mata uang pound sterling, dolar Kanada, dan yen dengan menggunakan metode GRNN, *Multi-Layered Feedforward Neural Network* (MLFN), dan *Multivariate Transfer Function*. Hasil yang didapatkan adalah bahwa prediksi dengan metode GRNN lebih baik daripada MLFN dan *Multivariate Transfer Function*. Hal ini ditunjukkan dengan nilai mean MAE dan RMSE untuk semua mata uang, kecuali pound sterling, lebih kecil dari metode lain.

Caraka, Yasin, dan Prahutama (2014) melakukan peramalan pada indeks Hangseng menggunakan *General Regression Neural Network* (GRNN) dengan peubah data *return*. Analisis dilakukan dengan menggunakan data masa lalu, yaitu pertama, kedua, dan keempat belas. Hasil yang didapatkan adalah pola data prediksi yang relatif mirip dengan data asli dan return indeks Hangseng bernilai positif serta negatif.

Adnyani dan Subanar (2015) melakukan peramalan dengan menggunakan *General Regression Neural Network* (GRNN) pada Indeks Harga Saham Gabungan (IHSG) dengan input kurs dolar dan data IHSG. Hasil yang didapatkan menyatakan bahwa nilai prediksi IHSG yang dihasilkan dengan metode GRNN lebih akurat dan lebih baik jika dibandingkan dengan metode ARIMA. Hal ini

ditunjukkan dengan nilai MSE pada metode GRNN lebih kecil dari nilai MSE pada metode ARIMA.

Analisis dari Rahayuningtyas, et al. (2021) yang menggunakan GRNN untuk memprediksi nilai tukar jual Yuan ke Rupiah dijadikan sebagai jurnal utama dalam skripsi ini. Input yang digunakan untuk memprediksi adalah nilai tukar beli Yuan ke Rupiah, inflasi, dan suku bunga acuan Bank Indonesia (*BI 7 Days Repo Rate*). Sebelumnya, data dibagi menjadi data pelatihan 80% dan data pengujian 20%. Analisis dilakukan dengan membandingkan standar deviasi pada data pengujian dan melihat hasil dari beberapa nilai kesalahan, yaitu MSE, RMSE, dan MAE. Hasil yang didapatkan adalah GRNN sudah bekerja dengan baik untuk menghasilkan prediksi harga jual Yuan ke Rupiah dengan menggunakan standar deviasi sebesar 0.1 dan nilai MSE, RMSE, dan MAE yang kecil.

Achyar dan Rohaen (2022) melakukan prediksi harga saham pada Indeks LQ45 dengan menggunakan GRNN serta menggunakan *Hybrid K-Means* untuk membagi data pelatihan berdasarkan karakteristik. Input yang digunakan adalah data masa lalu satu hari sebelumnya. Hasil analisis yang didapatkan adalah bahwa kinerja performa model prediksi sudah baik dengan dihasilkannya nilai MAPE sebesar 0.943%.

Pembeda penelitian pada skripsi ini dengan jurnal utama adalah terletak pada objek penelitian, dimana jurnal utama menggunakan data nilai tukar Yuan ke Rupiah, sedangkan penelitian ini menggunakan data Indeks Saham Syariah Indonesia. Input pada jurnal utama hanya menggunakan variabel lain di luar objek penelitian, sedangkan penelitian ini juga akan menggunakan data masa lalu, sehingga akan dibandingkan input dengan melihat nilai kesalahan dengan menggunakan MAE dan RMSE.

1.5 Metode Penelitian

Penelitian dilakukan dengan menggunakan metode penelitian studi kasus dan studi literatur. Studi kasus berkaitan tentang Indeks Saham Syariah Indonesia (ISSI), dimana data runtun waktu dari ISSI diambil dari data sekunder, melalui situs daring <https://id.investing.com>, sedangkan untuk data kurs jual, kurs beli,

dan inflasi melalui situs daring resmi Bank Indonesia. Semua data diambil secara harian dari tanggal 3 Januari 2022 hingga 31 Maret 2023. Studi literatur berasal dari sumber-sumber bacaan, seperti jurnal ilmiah, buku, skripsi, thesis, dan sebagainya terkait dengan teori-teori dari metode *General Regression Neural Network* (GRNN). Komputasi yang digunakan untuk memprediksikan harga penutupan Indeks Saham Syariah Indonesia (ISSI) adalah Python.

1.6 Sistematika Penulisan

Secara garis besar, tugas akhir ini memiliki lima bab dengan sistematika penulisan sebagai berikut:

BAB I PENDAHULUAN

Bab pendahuluan akan membahas terkait latar belakang, batasan masalah, tujuan penelitian, tinjauan pustaka, metode penelitian, dan sistematika penulisan. Dengan bab ini, terdapat acuan dan arahan dalam penulisan tugas akhir.

BAB II LANDASAN TEORI

Bab ini membahas terkait teori-teori yang mendukung pembahasan terkait *General Neural Network* dan dasar-dasar terkait Indeks Saham Syariah Indonesia sehingga dapat digunakan pada bab selanjutnya.

BAB III *GENERAL REGRESSION NEURAL NETWORK*

Bab ini membahas tentang *General Regression Neural Network* untuk dapat digunakan dalam permasalahan, yaitu prediksi harga terakhir Indeks Saham Syariah Indonesia.

BAB IV STUDI KASUS

Bab studi kasus ini akan membahas penerapan *General Regression Neural Network* untuk dapat memprediksi harga terakhir Indeks

Saham Syariah Indonesia dengan menggunakan *input* data masa lalu dan faktor lain, seperti kurs jual, kurs beli, dan inflasi.

BAB V PENUTUP

Bab penutup ini akan membahas tentang kesimpulan yang didapatkan dari bab studi kasus tentang prediksi harga terakhir Indeks Saham Syariah Indonesia menggunakan *General Regression Neural Network*. Selain itu, dibahas saran-saran yang dapat dilakukan untuk penelitian selanjutnya serta saran untuk para pembaca terkait prediksi yang dilakukan.

BAB II

LANDASAN TEORI

Pada bab ini, akan dibahas terkait konsep-konsep yang mendasari pembahasan bab-bab selanjutnya. Konsep yang akan di bahas antara lain peramalan, data *time series*, jaringan saraf tiruan, indeks harga saham, ISSI, dan konsep lainnya yang berkaitan dengan skripsi.

2.1 Peramalan

2.1.1 Pengertian Peramalan

Peramalan atau *forecasting* merupakan kegiatan untuk meramalkan atau memprediksi suatu hal di masa depan dengan hasil seakurat mungkin. Kegiatan ini memiliki banyak peran, baik dalam penelitian, perencanaan, maupun ketika ingin mengambil keputusan. Peramalan banyak digunakan dalam analisis ekonomi maupun kegiatan usaha di sebuah organisasi, terutama dalam berbagai bidang, mulai dari keuangan, produksi, atau pemasaran.

Ramalan adalah suatu kondisi yang diperkirakan akan terjadi di masa depan yang dapat didasarkan oleh berbagai cara, yaitu metode peramalan. Metode peramalan bergantung pada data masa lalu atau hal-hal yang memiliki hubungan dengan hasil prediksi sehingga metode diharapkan dapat memberikan objektivitas. Oleh karena itu, metode peramalan sangat berguna, sebab dapat membantu dalam mengadakan pendekatan analisis terhadap tingkah laku atau pola data masa lalu, sehingga dapat memberikan cara pemikiran, pengerjaan, dan juga pemecahan secara sistematis dan pragmatis, lalu memberikan tingkat keyakinan yang lebih besar pada ketetapan hasil ramalan yang dibuat atau disusun (Assauri, 1984).

2.1.2 Jenis-jenis Peramalan

Peramalan dapat dilihat dari beberapa sisi bergantung pada bagaimana cara melihatnya. Jika diklasifikasikan, peramalan dikelompokkan menjadi tiga jenis berdasarkan sifat yang mendasarinya.

a. Peramalan berdasarkan sifat penyusunnya

Terdapat dua macam peramalan jika dilihat dari sifat penyusunnya, yaitu:

1) Peramalan subjektif

Peramalan subjektif merupakan peramalan yang menggunakan aspek intuisi atau pandangan dari orang yang sedang melakukan peramalan, dengan hasil yang didapatkan akan bergantung kepada orang tersebut.

2) Peramalan objektif

Peramalan objektif merupakan peramalan yang menggunakan data sebagai landasannya, biasanya akan digunakan data masa lalu dan kemudian disusun dengan menggunakan metode-metode yang ada.

b. Peramalan berdasarkan jangka waktu ramalan

Terdapat dua macam peramalan jika dilihat dari jangka waktu ramalannya, yaitu:

1) Peramalan jangka panjang

Peramalan jangka panjang merupakan peramalan yang biasanya digunakan untuk menyusun perencanaan secara strategis dengan jangka waktu yang lama, seperti lebih dari satu setengah tahun. Diperlukan pertimbangan beberapa hal dalam peramalan ini, seperti peluang pasar, faktor lingkungan, dan sumber daya internal.

2) Peramalan jangka pendek

Peramalan jangka pendek merupakan peramalan yang biasanya digunakan untuk urusan yang personal atau urusan produksi, seperti rencana kerja operasional atau rencana anggaran perusahaan. Peramalan ini membutuhkan waktu yang lebih singkat, sekitar kurang dari satu tahun setengah.

c. Peramalan berdasarkan kategori jenis data

Terdapat dua macam peramalan jika dilihat dari kategori jenis data yang digunakan, yaitu:

1) Peramalan kualitatif

Peramalan kualitatif merupakan peramalan yang berdasarkan data kualitatif di masa lalu atau data yang tersedia tidak ada yang relevan dengan ramalan masa depan. Pada peramalan ini, hasil yang didapatkan akan bergantung pada orang yang sedang melakukan peramalan dan digunakan pemikiran yang memiliki sifat pendapat, intuisi, serta pengetahuan dari orang yang menyusun. Dalam peramalan kualitatif juga diperlukan pendapat dari para ahli yang bergerak di bidangnya masing-masing.

2) Peramalan kuantitatif

Peramalan kuantitatif memerlukan data sebagai sumber melakukan peramalan dan memiliki model matematikannya. Hasil dari peramalan kuantitatif berdasarkan pada metode yang digunakan, sebab metode yang berbeda akan menghasilkan hasil yang berbeda. Dengan ini, perlu diperhatikan penyimpangan antara hasil peramalan dan juga data asli. Terdapat beberapa metode peramalan yang termasuk pada peramalan kuantitatif, yaitu:

- a) Metode peramalan yang menggunakan dasar pada analisis pola hubungan antara variabel yang ingin diramalkan dengan variabel waktu, sehingga disebut dengan analisis *time series* atau deret waktu. Metode-metode yang menggunakan analisis *time series* dalam melakukan peramalan antara lain metode *smoothing*, Box-Jenkins, dan proyeksi tren dengan regresi.
- b) Metode peramalan yang menggunakan dasar pada analisis pola hubungan antara variabel yang ingin diramalkan dengan variabel lain yang mempengaruhinya, sehingga disebut dengan metode korelasi atau sebab akibat. Metode-metode yang menggunakan analisis korelasi dalam melakukan peramalan antara lain regresi dan korelasi, ekonometrik, dan metode *input output*.

2.2 Data Time Series

2.2.1 Pengertian Data Time Series

Data *time series* atau runtun waktu merupakan jenis data yang telah dikumpulkan berdasarkan urutan waktu tertentu. Metode statistik yang melakukan analisis pada data runtun waktu, disebut dengan analisis runtun waktu dan salah satunya dilakukan untuk melakukan peramalan pada suatu hal. Pada peramalan runtun waktu, dasar yang dimiliki adalah untuk mengamati hasil waktu sekarang atau kedepannya, maka diperlukan hasil pengamatan pada waktu yang sebelumnya.

2.2.2 Jenis-Jenis Pola Data Time Series

Pola yang ada pada data *time series* terbagi menjadi empat jenis (Hanke & Wichern, 2005), yaitu:

a. Pola horisontal (*Horizontal*)

Pola horisontal merupakan pola yang terjadi ketika data mengalami pergerakan di sekitar nilai rata-rata secara tetap dan stabil, sehingga dikenal dengan stasioner terhadap nilai rata-ratanya.

b. Pola musiman (*Seasonality*)


Pola musiman ini terjadi ketika data memiliki pola yang berulang setelah melewati periode tertentu, seperti contohnya periode mingguan, bulanan, enam bulan, atau tahunan.

c. Pola siklus (*Cycles*)

Pola siklus merupakan pola yang terjadi setiap beberapa tahun, yang seringkali terjadi karena pengaruh dari fluktuasi ekonomi pada waktu jangka panjang. Dengan ini, pola siklus sering dikaitkan dengan siklus dalam hal bisnis.

d. Pola tren (*Trend*)

Pola ini terjadi ketika terdapat kenaikan atau penurunan dari data secara gradual dalam jangka waktu yang panjang.



Gambar 2.1 Pola data runtun waktu

2.2.3 Jenis-Jenis Metode *Time Series*

Menurut Sofyan (2013), metode *time series* terbagi menjadi lima macam, yaitu:

a. Metode *Smoothing*

Metode *smoothing* merupakan metode yang melakukan peramalan dengan mengatur data-data di masa lalu sesuai dengan musiman data, atau dengan cara merata-ratakan beberapa data agar dapat memiliki jarak dan jumlah data yang cenderung seimbang. Metode ini terbagi menjadi dua jenis, yaitu *moving average* dan *exponential smoothing*.

b. Metode Proyeksi Kecenderungan dengan Regresi

Metode ini merupakan metode peramalan berdasarkan pada garis kecenderungan untuk meramalkan masa depan. Metode ini terbagi menjadi beberapa jenis, antara lain konstan dan kuadratis.

c. Metode Musiman (*seasonal*)

Metode musiman merupakan metode yang dipengaruhi oleh pola musiman yang berulang pada setiap periode. Cara untuk mendeteksi

adanya pola musiman adalah dengan melihat plot data asli setiap periode musim.

d. Metode Tren

Metode tren merupakan metode dengan data yang memiliki plot dengan kecenderungan naik atau turun pada setiap waktunya. Metode ini terbagi menjadi dua jenis, yaitu tren linear dan eksponensial.

e. Metode Dekomposisi

Pada metode dekomposisi, peramalan akan dibagi ke dalam beberapa komponen. Ketika terdapat kasus di mana data *time series* memiliki pola yang kompleks, seperti terdapat pola tren, musiman, dan siklis, maka metode dekomposisi akan digunakan. Seperti contoh, metode ini tidak menggunakan komponen dari tren dan siklis secara tunggal, tetapi akan digunakan gabungan dengan nama tren-siklis. Metode dekomposisi terbagi menjadi dua jenis, yaitu dekomposisi aditif dan dekomposisi multiplikatif.

2.3 Jaringan Saraf Tiruan

Jaringan saraf tiruan merupakan sebuah sistem pemrosesan informasi yang memiliki karakteristik yang mirip dengan jaringan saraf manusia (Hermawan, 2006). Jaringan saraf tiruan memiliki banyak elemen untuk melakukan kegiatan yang analog dengan fungsi biologis neuron, dimana elemen-elemen ini sudah terorganisir sebagaimana anatomi otak manusia bekerja. Algoritma jaringan saraf tiruan dioperasikan langsung dengan menggunakan angka, yang membuat data yang tidak numerik perlu diubah terlebih dahulu menjadi data numerik. Jaringan ini akan belajar dari pengalaman dan contoh selama dalam proses pembelajaran sehingga jaringan saraf tiruan tidak untuk menghasilkan keluaran tertentu. Pada proses pembelajaran, akan dimasukkan pola *input* serta *output* yang kemudian jaringan akan diberi pembelajaran dalam memberikan jawaban yang dapat diterima (Puspitaningrum, 2006).

Jaringan saraf tiruan dapat digunakan sebagai model matematis dan komputasi pada fungsi aproksimasi non-linear, klasifikasi cluster, dan regresi nonparametrik. Kemampuan pada jaringan saraf tiruan akan belajar dan juga

menghasilkan operasi beberapa contoh ataupun input yang masuk sehingga dapat memprediksi kemungkinan output atau menyimpan karakteristik input yang disimpan. Jaringan ini merupakan jaringan yang tidak transparan dalam menjelaskan bagaimana hasil didapatkan, sehingga membuat jaringan saraf tiruan dapat digunakan untuk permasalahan yang tidak terstruktur atau sulit untuk diidentifikasi. Karakteristik yang dimiliki jaringan saraf tiruan ditentukan oleh pola hubungan antara neuron atau yang biasa disebut arsitektur jaringan, metode penentuan bobot penyambung atau yang biasa disebut pelatihan jaringan, dan fungsi aktivasi.

Jaringan saraf tiruan memiliki kerangka kerja yang terdiri dari beberapa lapisan (*layer*) dan jumlah node pada setiap lapisan. Lapisan pertama adalah lapisan *input* yang memiliki node-node berupa unit-unit *input*. Pada lapisan ini, *input* data dari luar akan diterima dan akan mulai diproses pada lapisan selanjutnya. Kemudian, lapisan tersembunyi yang memiliki node-node, yaitu unit-unit tersembunyi. Hasil dari lapisan tersembunyi ini tidak dapat secara langsung diamati. Yang terakhir adalah lapisan *output* yang memiliki node-node berupa unit-unit *output*, dengan hasil yang akan dikeluarkan merupakan jawaban dari permasalahan.

Jaringan saraf perlu adanya penyesuaian bobot selama pelatihan. Pelatihan dapat berupa pelatihan terbimbing (*supervised training*) dan pelatihan tidak terbimbing (*unsupervised training*). Pada pelatihan terbimbing, perlu adanya data masukan untuk dapat memperoleh target pada pola yang dilatihkan. Biasanya pelatihan terbimbing akan digunakan untuk melakukan prediksi pada suatu hal. Sedangkan pada pelatihan tidak terbimbing, tidak diperlukan target, sehingga jaringan akan mengklasifikasikan pola berdasarkan kategori yang sama.

2.3.1 Jenis-Jenis Jaringan Saraf Tiruan

Pengelompokkan jaringan saraf tiruan dapat dibagi menjadi dua kelompok, yaitu jaringan saraf tiruan umpan maju atau disebut dengan *feed forward neural network* dan jaringan saraf tiruan berulang umpan balik atau yang disebut dengan *recurrent/feedback neural network* (Puspitaningrum, 2006).

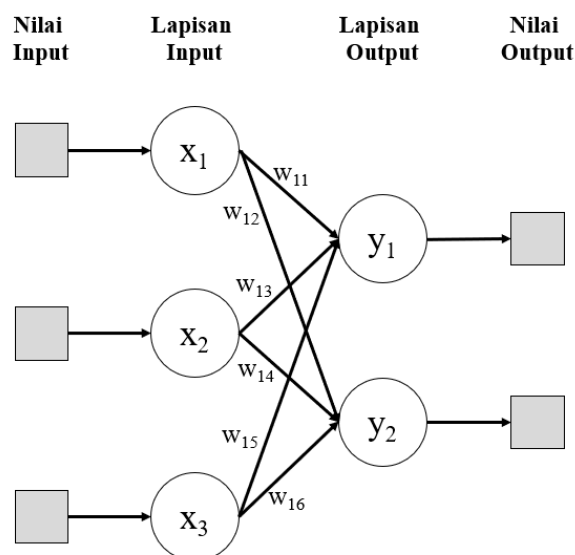
1. *Feed forward neural network* merupakan jaringan saraf tiruan yang tidak memiliki loop pada prosesnya dan akan bergerak maju. Contoh dari *feed forward neural network* antara lain *single-layer perceptron*, *multilayer perceptron*, dan *radial basis function*.
2. *Recurrent/feedback neural network* merupakan jaringan saraf tiruan yang memiliki loop koneksi pada prosesnya. Contoh dari *recurrent/feedback neural network* antara lain *competitive networks*, *kononen's SOM*, *hopfield network*, dan *ART models*.

2.3.2 Arsitektur Jaringan Saraf Tiruan

Arsitektur yang dimiliki jaringan saraf tiruan akan menentukan kesuksesan output yang dihasilkan, sebab setiap permasalahan tidak semua dapat diselesaikan dengan arsitektur yang sama (Hermawan, 2006). Jaringan saraf tiruan terbagi menjadi tiga macam arsitektur, antara lain:

1) Jaringan lapis tunggal (*single-layer*)

Jaringan saraf tiruan dengan satu lapisan ini hanya memiliki satu lapisan dengan bobot yang terhubung. Dengan kata lain, pada jaringan saraf tiruan ini, ketika input diterima, maka input tersebut akan langsung diproses menjadi output tanpa harus melewati lapisan tersembunyi.

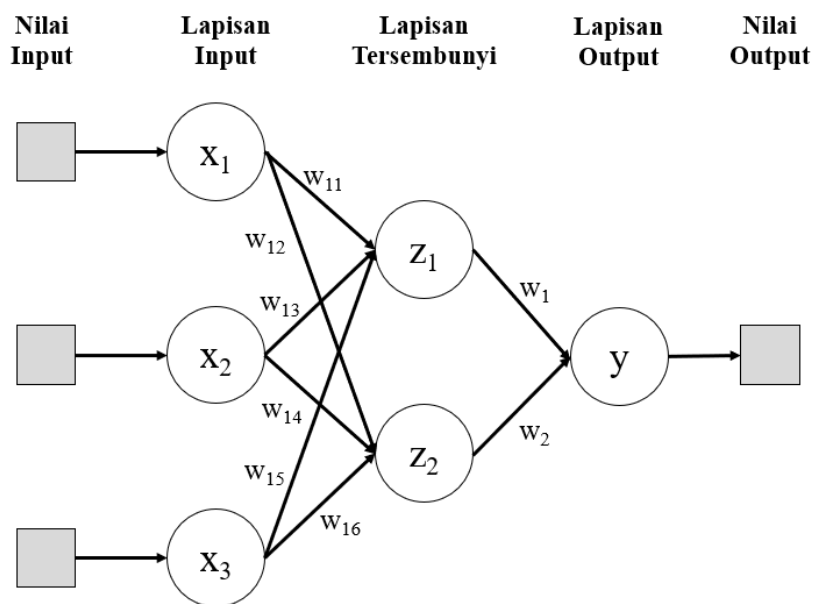


Gambar 2.2 Jaringan saraf tiruan lapisan tunggal

Variabel X_1, X_2, X_3 merupakan nilai *input* yang dimasukkan pada tahap awal, $w_{11}, w_{12}, \dots, w_{16}$ merupakan nilai bobot yang menghubungkan lapisan *input* dan *output*, dan y_1, y_2 merupakan hasil dari proses jaringan saraf tiruan.

2) Jaringan multilapis

Jaringan multilapis merupakan lapisan yang memiliki satu atau lebih lapisan di antara lapisan input dan lapisan output. Biasanya terdapat bobot yang letaknya di antara dua lapisan yang bersebelahan.




Gambar 2.3 Jaringan saraf tiruan multilapis

Variabel x_1, x_2, x_3 merupakan nilai input, $w_{11}, w_{12}, \dots, w_{16}$ bobot di antara lapisan *input* dan lapisan tersembunyi, w_1, w_2 merupakan nilai bobot di antara lapisan tersembunyi dan lapisan *output*, dan y merupakan hasil dari jaringan saraf tiruan.

3) Jaringan dengan lapisan kompetitif

Hubungan antara neuron pada lapisan jaringan ini tidak ditunjukkan pada arsitektur seperti jaringan lainnya dan kumpulan neuron akan bersaing untuk mendapatkan hak aktif. Dengan ini sering disebut sebagai *winner-take-all*, dimana hanya neuron yang mewakili suatu input saja yang dapat digunakan. Seperti contoh pada perhitungan dengan menggunakan jarak, neuron yang memiliki nilai terdekat dengan nilai input yang akan digunakan untuk melanjutkan proses pada jaringan saraf tiruan. Gambar 2.4 merupakan contoh dari arsitektur jaringan saraf tiruan yang menggunakan lapisan kompetitif dengan bobot $-\eta$.



Gambar 2.4 Jaringan saraf tiruan lapisan kompetitif

2.4 Norma Euclidean

Norma euclidean merupakan pengukuran jarak terdekat suatu titik ke pusat. Perhitungan dilakukan dengan akar dari penjumlahan kuadrat komponen-komponen yang ada dalam vektor (Pandey, 2022). Norma euclidean untuk vektor $\mathbf{x} = (x_1, x_2, \dots, x_n)$ adalah sebagai berikut:

$$\|\mathbf{x}\| = \sqrt{x_1^2 + x_2^2 + \dots + x_n^2}. \quad (2.1)$$

Contoh 2.4.1 Diberikan vektor $\mathbf{x} = (5,3)$, maka norma euclidean vektor \mathbf{x} adalah

$$\|\mathbf{x}\| = \sqrt{5^2 + 3^2} = \sqrt{25 + 9} = \sqrt{34}.$$

2.5 Jaringan Radial Basis

Jaringan radial basis merupakan jaringan yang berkonsep pada pengolahan nilai *output* yang akan diproses dengan kombinasi linear fungsi aktivasi dan nilai *input*. Persamaan dari fungsi aktivasi yang sering digunakan adalah fungsi radial basis gaussian untuk menghasilkan *output* sebuah neuron (Sitamahalakshmi, Babu, Jagadeesh, & Mouli, 2011).

$$G(\mathbf{x} - \mu_i) = \exp\left(-\frac{\|\mathbf{x} - \mu_i\|^2}{2\sigma^2}\right) \quad (2.2)$$

dengan \mathbf{x} adalah input, μ_i adalah pusat neuron, $\|\mathbf{x} - \mu_i\|$ merupakan jarak euclidean antara input dan pusat neuron, $\|\cdot\|$ merupakan norma jarak euclidean, dan σ adalah *spread*. Fungsi radial basis akan menghasilkan nilai maksimum satu ketika input yang dimasukkan bernilai nol atau jarak antar bobot dengan input adalah nol. Jika jarak di antara bobot dan input berkurang, maka fungsi radial basis akan menghasilkan output yang lebih besar. Jaringan radial basis terdiri dari tiga lapisan, yaitu lapisan input, satu lapisan tersembunyi yang fungsi aktivasinya berbasis radial, dan lapisan output yang fungsi aktivasinya linear (*purelin*).


2.6 Fungsi Aktivasi

Fungsi aktivasi digunakan untuk memberikan sinyal pada penentuan *output* dari suatu neuron. Terdapat beberapa jenis fungsi aktivasi (Hermawan, 2006), antara lain fungsi identitas, fungsi biner dengan ambang batas, fungsi biner sigmoid, dan fungsi sigmoid bipolar.

1) Fungsi identitas

Fungsi identitas merupakan fungsi ketika nilai output yang akan dihasilkan adalah bilangan riil dan bukan bilangan pada rentang tertentu.

$$f(x) = x. \quad (2.3)$$




Gambar 2.5 Fungsi identitas

2) Fungsi biner dengan batas ambang

Fungsi ini juga dapat disebut fungsi *threshold binary*, biasa digunakan pada jaringan dengan lapisan tunggal untuk mengubah nilai input. Dimana nilai input yang semula merupakan variabel kontinu akan diubah menjadi biner, dengan nilai 0 atau 1, atau bipolar, dengan nilai -1 atau 1.

$$f(x) = \begin{cases} 1 & \text{untuk } x \geq \theta \\ 0 & \text{untuk } x < \theta \end{cases} \quad (2.4)$$




Gambar 2.6 Fungsi biner dengan ambang batas

3) Fungsi biner sigmoid

Fungsi biner sigmoid juga merupakan fungsi yang dapat digunakan untuk fungsi aktivasi yang akan menghasilkan nilai output di antara nilai 0 dan 1. Persamaan fungsi biner sigmoid adalah sebagai berikut:

$$f(x) = \frac{1}{1 + \exp(-\sigma x)} \quad (2.5)$$




Gambar 2.7 Fungsi biner sigmoid dengan $\sigma = 1$ dan $\sigma = 3$

4) Fungsi sigmoid bipolar

Fungsi sigmoid bipolar merupakan fungsi yang digunakan untuk aktivasi dengan rentang nilai output di antara -1 dan 1. Persamaan fungsi sigmoid bipolar adalah sebagai berikut:

$$\begin{aligned}
 g(x) &= 2f(x) - 1 \\
 &= \frac{2}{1 + \exp(-\sigma x)} - 1 \\
 &= \frac{1 - \exp(-\sigma x)}{1 + \exp(-\sigma x)}.
 \end{aligned} \tag{2.6}$$



Gambar 2.8 Fungsi sigmoid bipolar

2.7 Regresi Kernel

Regresi kernel merupakan suatu teknik statistik nonparametrik yang digunakan untuk mengestimasi ekspektasi bersyarat variabel acak dengan tujuan untuk melihat hubungan variabel dependen (y) dan variabel independen (x) dengan model sebagai berikut:

$$y = m(x_i) + \varepsilon \tag{2.7}$$

dengan m merupakan fungsi regresi dan ε merupakan *error*. Persamaan model regresi kernel tersebut tidak dapat diwujudkan, tetapi $m(x)$ dapat diestimasi dengan pendekatan nonparametrik.

$$E(Y|X) = \hat{m}(x) = \frac{\sum_{i=1}^n y_i w\left(\frac{x - X_i}{\Delta}\right)}{\sum_{i=1}^n w\left(\frac{x - X_i}{\Delta}\right)} \quad (2.8)$$

dengan $w\left(\frac{x - X_i}{\Delta}\right)$ merupakan kernel, x merupakan titik jangkauan, X_i merupakan data ke- i , dan Δ merupakan *bandwidth*. *Bandwidth* memiliki fungsi untuk mengontrol kemulusan pada regresi kernel. Ketika *bandwidth* terlalu sempit, maka data akan terlalu fluktuatif, dan ketika *bandwidth* terlalu lebar, maka tampilan akan menjadi terlalu halus.

2.8 Ukuran Ketepatan Nilai Peramalan

Ukuran ketepatan nilai peramalan dapat dilihat dari seberapa besar kesalahan peramalan atau prediksi yang sudah dilakukan, atau dengan kata lain, dilakukan perbandingan hasil ramalan dengan nilai dari data asli. Ukuran nilai kesalahan peramalan yang semakin tinggi, menandakan bahwa semakin kecil tingkat ketelitian dalam meramalkan. Begitu pun sebaliknya, ketika ukuran nilai kesalahan semakin kecil, maka semakin tinggi tingkat ketelitiannya.

Metode-metode dalam menghitung ukuran ketepatan nilai peramalan antara lain sebagai berikut:

1) *Mean Absolute Percentage Error* (MAPE)

Ukuran ketepatan *Mean Absolute Percentage Error* (MAPE) digunakan jika ingin mengetahui persentase dari kesalahan hasil ramalan.

$$MAPE = \frac{\sum_{t=1}^n \left| \frac{y_t - \hat{y}_t}{y_t} \right|}{n} \times 100. \quad (2.9)$$

2) *Mean Absolute Deviation / Error* (MAD/MAE)

Mean Absolute Deviation (MAD) atau *Mean Absolute Error* (MAE) digunakan dalam menyatakan kesalahan peramalan dengan rata-rata nilai

absolut *error* dari seluruh peramalan. Ukuran ini tidak memperhatikan apakah hasil dari peramalan lebih besar atau lebih kecil dari nilai asli.

$$MAE = \frac{\sum_{t=1}^n |y_t - \hat{y}_t|}{n}. \quad (2.10)$$

3) *Mean Squared Deviation / Error* (MSD/MSE)

MSD atau MSE merupakan ukuran ketepatan peramalan dengan melakukan rata-rata kuadrat *error* dari seluruh peramalan.

$$MSE = \frac{\sum_{t=1}^n |y_t - \hat{y}_t|^2}{n}. \quad (2.11)$$

4) *Root Mean Squared Error* (RMSE)

Root Mean Squared Error (RMSE) merupakan ukuran ketepatan peramalan dengan menggunakan akar dari MSE.

$$RMSE = \sqrt{\frac{\sum_{t=1}^n |y_t - \hat{y}_t|^2}{n}}, \quad (2.12)$$

dengan

y_t : nilai data asli,

\hat{y}_t : nilai hasil ramalan,

n : jumlah periode data.

2.9 Model Autoregressive (AR) dan Moving Average (MA)

Model *autoregressive* (AR) biasa dinotasikan dengan AR(p) merupakan kombinasi linear dari nilai-nilai variabel respons di masa lalu, dengan p menyatakan banyak nilai di masa lalu yang akan mempengaruhi peramalan periode ke depan. Berikut merupakan definisi terkait model *autoregressive* (AR):

Definisi 2.1 (Rosadi, 2021) Proses $\{X_t\}$ disebut dengan model autoregressive (AR) orde p atau $AR(p)$ didefinisikan sebagai persamaan

$$X_t = a_1X_{t-1} + a_2X_{t-2} + \dots + a_pX_{t-p} + \varepsilon_t, t \in \mathbb{Z} \quad (2.13)$$

di mana a_1, a_2, \dots, a_p adalah koefisien parameter AR, $X_{t-1}, X_{t-2}, \dots, X_{t-p}$ adalah nilai masa lalu, dan ε_t merupakan *error*. Dengan mendefinisikan operator *backward-shift (lag operator)* untuk mentransformasi proses $\{X_t\}$ sebagai:

$$(B^j X)_t = X_{t-j} \quad j, t \in \mathbb{Z}, \quad (2.14)$$

di mana j merupakan jumlah periode sebelumnya, maka proses $AR(p)$ dapat ditulis sebagai berikut

$$\begin{aligned} X_t - a_1X_{t-1} - a_2X_{t-2} - \dots - a_pX_{t-p} &= \varepsilon_t \\ X_t - a_1(B^1X)_t - a_2(B^2X)_t - \dots - a_p(B^pX)_t &= \varepsilon_t \\ (1 - a_1B - a_2B^2 - \dots - a_pB^p)X_t &= \varepsilon_t \\ D(B)X_t &= \varepsilon_t \end{aligned} \quad (2.15)$$

dengan polinomial $D(z) = (1 - a_1z - a_2z^2 - \dots - a_pz^p)$.

Model *moving average* (MA) merupakan model yang menggunakan *error* peramalan pada masa lalu sebagai variabel independennya. Berikut merupakan definisi terkait model *moving average* (MA):

Definisi 2.2 (Rosadi, 2021) Proses $\{X_t\}$ merupakan proses *moving average* (MA) dengan orde q atau $MA(q)$ didefinisikan sebagai persamaan

$$X_t = b_0\varepsilon_t + b_1\varepsilon_{t-1} + b_2\varepsilon_{t-2} + \dots + b_q\varepsilon_{t-q} = \sum_{j=0}^q b_j\varepsilon_{t-j} \quad (2.16)$$

di mana $b_0 = 1$, b_1, b_2, \dots, b_q adalah parameter MA, $\varepsilon_{t-1}, \varepsilon_{t-2}, \dots, \varepsilon_{t-q}$ adalah nilai *error* masa lalu, dan ε_t adalah nilai *error* waktu ke- t . Dengan mendefinisikan operator *backward-shift (lag operator)* untuk proses $\{X_t\}$ sebagai

$$(B^j \varepsilon)_t = \varepsilon_{t-j} \quad j, t \in \mathbb{Z}, \quad (2.17)$$

di mana j merupakan jumlah periode sebelumnya, maka proses $MA(q)$ dapat ditulis dengan

$$\begin{aligned}
b_0\varepsilon_t + b_1\varepsilon_{t-1} + b_2\varepsilon_{t-2} + \cdots + b_q\varepsilon_{t-q} &= X_t \\
\varepsilon_t + b_1(B^1\varepsilon)_t + b_2(B^2\varepsilon)_t + \cdots + b_q(B^q\varepsilon)_t &= X_t \\
(1 + b_1B + b_2B^2 + \cdots + b_qB^q)\varepsilon_t &= X_t \\
C(B)\varepsilon_t &= X_t
\end{aligned} \tag{2.18}$$

dengan polinomial $C(z) = (1 + b_1z + b_2z^2 + \cdots + b_qz^q)$.

2.10 Fungsi Autokorelasi Parsial (PACF)

Fungsi Autokorelasi Parsial atau yang disebut PACF (*Partial Autocorrelation Function*) pada lag ke ke- k merupakan sebuah korelasi yang terjadi di antara X_t dan X_{t+k} setelah dilakukan penghapusan pada dependensi linear X_t dan X_{t+k} variabel antara $X_{t+1}, X_{t+2}, \dots, X_{t+k-1}$. Terdapat beberapa prosedur yang dapat dilakukan dalam penentuan bentuk PACF.

Misalkan $\{X_t\}$ merupakan suatu proses stasioner dengan *mean* nol dan X_{t+k} ditulis sebagai model linear.

$$X_{t+k} = a_{k1}X_{t+k-1} + a_{k2}X_{t+k-2} + \cdots + a_{kk}X_t + \varepsilon_{t+k}, \tag{2.19}$$

dengan a_{ki} merupakan parameter ke- i dari persamaan regresi dan ε_{t+k} merupakan komponen *error* yang tidak memiliki korelasi dengan Y_{t+k-j} untuk $j \geq 1$. Kemudian dilakukan perkalian pada kedua sisi dengan X_{t+k-j} dan diambil ekspektasinya, sehingga didapatkan

$$\gamma(j) = a_{k1}\gamma(j-1) + a_{k2}\gamma(j-2) + \cdots + a_{kk}\gamma(j-k), \tag{2.20}$$

lalu kedua sisi dibagi dengan $\gamma(0)$ dan diperoleh

$$\rho(j) = a_{k1}\rho(j-1) + a_{k2}\rho(j-2) + \cdots + a_{kk}\rho(j-k). \tag{2.21}$$

Untuk $j = 1, 2, \dots, k$ diperoleh sistem persamaan:

$$\begin{aligned}
\rho(1) &= a_{k1}\rho(0) + a_{k2}\rho(1) + \cdots + a_{kk}\rho(k-1) \\
\rho(2) &= a_{k1}\rho(1) + a_{k2}\rho(0) + \cdots + a_{kk}\rho(k-2) \\
&\vdots \\
\rho(k) &= a_{k1}\rho(k-1) + a_{k2}\rho(k-2) + \cdots + a_{kk}\rho(0).
\end{aligned} \tag{2.22}$$

Substitusi $\rho(-k) = \rho(k)$ dan dengan metode Cramer untuk $k = 1, 2, \dots$ diperoleh

$$\begin{aligned}
 a_{11} &= \rho(1) \\
 a_{22} &= \frac{\begin{vmatrix} 1 & \rho(1) \\ \rho(1) & \rho(2) \end{vmatrix}}{\begin{vmatrix} 1 & \rho(1) \\ \rho(1) & 1 \end{vmatrix}} \\
 a_{33} &= \frac{\begin{vmatrix} 1 & \rho(2) & \rho(1) \\ \rho(1) & 1 & \rho(2) \\ \rho(2) & \rho(1) & 1 \end{vmatrix}}{\begin{vmatrix} 1 & \rho(1) & \rho(2) \\ \rho(1) & 1 & \rho(2) \\ \rho(2) & \rho(1) & 1 \end{vmatrix}} \\
 &\vdots \\
 a_{kk} &= \frac{\begin{vmatrix} 1 & \rho(1) & \dots & \rho(k-2) & \rho(1) \\ \rho(1) & 1 & \dots & \rho(k-3) & \rho(2) \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ \rho(k-1) & \rho(k-2) & \dots & \rho(1) & \rho(k) \end{vmatrix}}{\begin{vmatrix} 1 & \rho(1) & \dots & \rho(k-2) & \rho(k-1) \\ \rho(1) & 1 & \dots & \rho(k-3) & \rho(k-2) \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ \rho(k-1) & \rho(k-2) & \dots & \rho(1) & 1 \end{vmatrix}}. \tag{2.23}
 \end{aligned}$$

2.11 Uji Korelasi

Uji korelasi dilakukan untuk mengetahui hubungan antara sebuah variabel dengan variabel lain. Ukuran statistika yang dapat menjelaskan hubungan antar variabel adalah koefisien korelasi. Selain untuk melihat keeratan hubungan di antara dua variabel, koefisien korelasi juga dapat digunakan dalam melihat arah hubungan kedua variabel tersebut. Keeratan hubungan didapatkan dengan menggunakan nilai koefisien korelasi, dimana besarnya dari nol sampai dengan ± 1 .

Ketika kedua variabel memiliki nilai koefisien korelasi sebesar nol, maka disimpulkan bahwa tidak ada hubungan. Sedangkan ketika kedua variabel memiliki nilai sebesar ± 1 , maka terdapat hubungan yang sempurna (Algifari, 1997). Semakin tinggi nilai koefisien korelasi (mendekati ± 1), maka tingkat keeratan yang dimiliki kedua variabel juga semakin tinggi. Begitupun sebaliknya,

semakin rendah nilai koefisien korelasi (mendekati 0), maka tingkat keeratan yang dimiliki semakin lemah.

Untuk melihat arah hubungan kedua variabel, dapat dilihat dengan melihat tanda positif (+) dan negatif (−) yang ada di nilai koefisien korelasi. Tanda positif (+) menunjukkan bahwa arah hubungan bersifat searah, atau ketika satu nilai variabel mengalami kenaikan, maka nilai variabel yang lain juga akan naik. Tanda negatif (−) menunjukkan arah hubungan kedua variabel yang berlawanan arah, atau ketika satu nilai variabel naik, maka nilai variabel yang lain akan turun.

Koefisien korelasi dapat dihitung dengan beberapa metode berikut:

1. Korelasi Pearson

Korelasi Pearson biasa digunakan untuk data yang berdistribusi normal, sehingga termasuk ke dalam statistik parametrik. Koefisien korelasi Pearson dapat dihitung dengan persamaan:

$$r_p = \frac{n \sum XY - \sum X \sum Y}{\left[\sqrt{n \sum X^2 - (\sum X)^2} \right] \left[\sqrt{n \sum Y^2 - (\sum Y)^2} \right]} \quad (2.24)$$

dengan

r_p : koefisien korelasi Pearson,

n : banyak data,

X : nilai variabel X,

Y : nilai variabel Y.

2. Korelasi Spearman

Korelasi spearman ini dikembangkan oleh Carl Spearman pada tahun 1904. Korelasi ini termasuk ke dalam statistik nonparametrik, dimana tidak ada permasalahan dalam distribusi datanya. Korelasi Spearman dilakukan dengan membuat ranking pada masing-masing variabel. Koefisien korelasi Spearman dapat dihitung dengan persamaan:

$$r_s = 1 - \frac{6 \sum d^2}{n(n^2 - 1)} \quad (2.25)$$

dengan

r_s : koefisien korelasi Spearman,

d : perbedaan ranking kedua variabel,

n : banyak pasangan data.

2.12 Indeks Harga Saham

Indeks Harga Saham (IHS) merupakan ringkasan dari pengaruh simultan dan kompleks dari beberapa macam variabel yang berpengaruh, terutama tentang kejadian-kejadian ekonomi (Halim, 2003). Selain dari kejadian ekonomi, IHS juga dapat berasal dari kejadian sosial, politik, dan keamanan. Dengan ini, IHS dijadikan tolak ukur dari kesehatan ekonomi negara dan dasar dalam melakukan analisis statistik pada kondisi pasar terakhir (*current market*). IHS berfungsi untuk memberikan jawaban terkait apa yang terjadi di pasar sehingga diperlukan untuk para pelaku pasar (Moechdie & Ramelan, 2012). Indeks Harga Saham memiliki fungsi lain, seperti sebagai tolak ukur dari kinerja investasi dan untuk memprediksikan pergerakan harga di masa depan dengan melihat perubahan-perubahan indeks di masa lalu.

Pada Bursa Efek Indonesia (BEI), terdapat beberapa jenis indeks saham yang digunakan, seperti contohnya adalah

1. Indeks Harga Saham Gabungan (IHSG)

Indeks Harga Saham Gabungan (IHSG) merupakan indeks harga saham yang pertama kali diterbitkan, yaitu tanggal 1 April 1983. IHSG memiliki fungsi untuk mencerminkan perkembangan harga di BEI secara umum. Perhitungan indeks harga saham ini perlu melibatkan semua saham yang tercatat di BEI agar didapatkan gambaran tentang keadaan pasar.

2. Indeks LQ45

Indeks LQ45 dibuat oleh BEI dengan tujuan untuk melihat pergerakan dari 45 jenis saham yang paling sering ditransaksikan selama periode tertentu

dan untuk mempertimbangkan kapitalisasi pasar dari saham-saham tersebut. (Moechdie & Ramelan, 2012). Untuk dapat masuk ke dalam indeks ini, saham-saham perlu memenuhi beberapa kriteria yang dibutuhkan.

3. Indeks Sektor

Indeks sektor akan mengukur kinerja dari harga di semua saham pada masing-masing sektor dengan mengacu pada klasifikasi *IDX Industrial Classification* (IDX-IC). Terdapat beberapa sektor yang memiliki indeks saham, seperti sektor energi, barang baku, perindustrian, barang konsumen primer, barang konsumen non-primer, kesehatan, keuangan, properti dan *real estat*, teknologi, infrastruktur, serta transportasi dan logistik.

4. Indeks Saham Syariah Indonesia (ISSI)

Indeks Saham Syariah Indonesia (ISSI) merupakan indeks saham yang menjadi indikator kinerja pasar saham syariah yang tercatat di BEI. Konstituen dari ISSI merupakan semua saham syariah yang berada pada Daftar Efek Syariah (DES) yang diterbitkan Otoritas Jasa Keuangan (OJK).

5. Jakarta Islamic Index (JII)

Jakarta Islamic Index (JII) merupakan salah satu indeks saham syariah yang pertama kali diterbitkan, yaitu tanggal 3 Juli 2000. JII hanya terdiri dari 30 saham syariah paling likuid yang tercatat di BEI. Untuk dapat menjadi salah satu dari JII, saham syariah juga memiliki beberapa kriteria likuiditas, seperti saham syariah yang telah masuk ISSI selama enam bulan terakhir, yang kemudian diurutkan 60 saham berdasarkan rata-rata kapitalisasi pasar tertinggi selama satu tahun terakhir, dan dipilih 30 saham berdasarkan pada rata-rata nilai transaksi harian pasar reguler tertinggi.

6. IDX-MES BUMN 17

Indeks ini akan mengukur kinerja dari 17 saham syariah yang dimiliki oleh Badan Usaha Milik Negara (BUMN) dengan likuiditas baik dan kapitalisasi pasar besar. Indeks ini merupakan indeks hasil kerja sama antara BEI dan Perkumpulan Masyarakat Ekonomi Syariah (MES). Saham syariah yang dapat menjadi konstituen dalam indeks ini juga perlu memenuhi kriteria.

2.13 Indeks Saham Syariah Indonesia

Indeks Saham Syariah Indonesia atau yang biasa disebut ISSI merupakan salah satu indeks harga saham syariah yang diterbitkan oleh BEI. Indeks ini pertama kali muncul pada tanggal 12 Mei 2011. ISSI digunakan sebagai sarana untuk memudahkan investor dalam memilih investasi di pasar modal dengan berlandaskan pada syariah dan agama Islam. Indeks ini akan mengikuti prinsip serta prosedur pengaplikasian yang berdasarkan pada nilai-nilai Islam, yaitu Al-Quran dan Sunnah yang disajikan dalam fatwa DSN-MUI terkait modal syariah (Pasaribu & Firdaus, 2013). Dari fatwa ini, diaplikasikan oleh lembaga pengawas Bapepam-LK dan pelaksana, yaitu BEI, emiten, dan investor.

Seluruh saham syariah yang berada di Daftar Efek Syariah (DES) akan menjadi konstituen dari ISSI. Penyeleksian konstituen ISSI dilakukan sebanyak dua kali dalam satu tahun, yaitu pada bulan Mei dan bulan November. Oleh karena itu, di periode penyeleksian, akan ada saham syariah yang keluar atau juga masuk dengan pengumuman di awal bulan berikutnya. Metode perhitungan ISSI adalah dengan rata-rata kapitalisasi pasar dengan menggunakan bulan Desember 2007 sebagai tahun dasar perhitungan ISSI, dimana bulan ini merupakan awal penerbitan DES.

2.14 Faktor Makroekonomi

Faktor makroekonomi merupakan faktor-faktor yang mempengaruhi perekonomian nasional secara umum (Andayani, 2021). Pada pasar modal, harga saham akan merespon cepat ketika ada perubahan pada faktor makroekonomi dibandingkan kinerja perusahaan. Menurut Sjahrir (1995), faktor-faktor makroekonomi yang dapat mempengaruhi perkembangan indeks saham syariah adalah variabel makroekonomi dan moneter, seperti inflasi, nilai tukar rupiah, Sertifikat Bank Indonesia, jumlah uang beredar, dan lain-lain. Menurut Suciningtias dan Khoiroh (2015), faktor-faktor makroekonomi yang memiliki hubungan dengan ISSI adalah Inflasi dan Nilai Tukar.

Inflasi merupakan kejadian ketika harga-harga barang dan jasa akan meningkat secara terus menerus dalam jangka waktu tertentu. Jika hanya satu atau

dua barang saja yang meningkat, maka tidak dapat disebut sebagai inflasi, kecuali kenaikan tersebut meluas dan berefek kepada kenaikan harga pada barang lainnya. Inflasi dihitung oleh Badan Pusat Statistika (BPS) dengan cara melakukan survei kepada harga barang dan jasa di masyarakat dan kemudian dibandingkan dengan harga pada periode sebelumnya.

Nilai tukar atau biasa disebut dengan kurs merupakan harga atau nilai mata uang suatu negara terhadap mata uang lainnya (Wiriani & Mukarramah, 2020). Ketika kurs meningkat, mata uang dalam negeri mengalami depresiasi dan begitu pun sebaliknya (Sari, 2017). Kurs dapat dibedakan menjadi dua, yaitu kurs jual dan kurs beli. Kurs jual dilakukan ketika bank atau *money changer* ingin menjual mata uang asing atau menukarkan rupiah dengan mata uang asing. Kurs beli dilakukan ketika bank atau *money changer* ingin membeli mata uang asing atau menukarkan mata uang asing dengan rupiah. Nilai kurs dapat berubah dari waktu ke waktu karena disebabkan oleh beberapa hal, seperti adanya perubahan harga barang ekspor dan impor, terjadinya inflasi, dan perubahan selera di masyarakat.

BAB III

GENERAL REGRESSION NEURAL NETWORK

General Regression Neural Network (GRNN) pertama kali dikembangkan oleh Specht pada tahun 1991. GRNN merupakan *feedforward neural network*, dimana prosesnya adalah untuk merespon lapisan *input* dengan memproses data *input* dari satu lapisan ke lapisan selanjutnya tanpa adanya jalur balik dan juga merupakan salah satu dari jaringan radial basis yang digunakan pada pendekatan suatu fungsi. GRNN didasarkan pada teori regresi non linear (*kernel*) dengan estimasi nilai harapan dari *output* ditentukan dari himpunan *input*. Metode ini dapat digunakan untuk melakukan peramalan atau prediksi pada data historis dengan hasil dari variabel *output* didasarkan pada minimal satu variabel *input*.

Persamaan 3.1 menunjukkan persamaan nilai ekspektasi y terhadap \mathbf{X} (atau juga disebut regresi y pada \mathbf{X}).

$$E[y|\mathbf{X}] = \frac{\int_{-\infty}^{\infty} yf(\mathbf{X}, y) dy}{\int_{-\infty}^{\infty} f(\mathbf{X}, y) dy} \quad (3.1)$$

dengan keterangan y merupakan nilai prediksi atau nilai *output* yang dihasilkan, \mathbf{X} merupakan vektor input (x_1, x_2, \dots, x_n) dengan n adalah jumlah dari variabel *input* atau variabel prediktor, $E[y|\mathbf{X}]$ merupakan nilai ekspektasi dari *output* y berdasarkan vektor \mathbf{X} , dan $f(\mathbf{X}, y)$ merupakan fungsi kepadatan probabilitas (*probability density function/pdf*) kontinu gabungan antara \mathbf{X} dan y .

Ketika $f(\mathbf{X}, y)$ tidak diketahui, biasanya akan diestimasi dari sampel observasi \mathbf{x} dan y . Untuk estimasi non parametrik $f(\mathbf{X}, y)$, dapat digunakan estimasi yang dikembangkan oleh Parzen, yang ditunjukkan dengan persamaan (3.2).

$$\hat{f}(\mathbf{X}, y) = \frac{1}{(2\pi)^{\frac{p+1}{2}} \sigma^{p+1}} \cdot \frac{1}{n} \sum_{i=1}^n \exp \left[-\frac{(\mathbf{X} - \mathbf{X}_i)^T (\mathbf{X} - \mathbf{X}_i)}{2\sigma^2} \right] \cdot \exp \left[-\frac{(y - y_i)^2}{2\sigma^2} \right], \quad (3.2)$$

dengan estimasi probabilitas $\hat{f}(\mathbf{X}, y)$ berdasarkan pada nilai sampel \mathbf{X}_i dan y_i dari nilai random \mathbf{X} dan y . Kemudian, n adalah jumlah sampel oservasi, p adalah dimensi dari vektor variabel \mathbf{x} , dan σ adalah paramater *smoothing*.

Dilakukan subsitusi dari persamaan (3.2) ke persamaan (3.1), sehingga didapatkan:

$$\begin{aligned}
 E[y|\mathbf{X}] &= \frac{\int_{-\infty}^{\infty} \frac{1}{(2\pi)^{\frac{p+1}{2}} \sigma^{p+1}} \cdot \frac{1}{n} \sum_{i=1}^n \exp\left[-\frac{(\mathbf{X} - \mathbf{X}_i)^T(\mathbf{X} - \mathbf{X}_i)}{2\sigma^2}\right] \cdot \exp\left[-\frac{(y - y_i)^2}{2\sigma^2}\right] \cdot y \, dy}{\int_{-\infty}^{\infty} \frac{1}{(2\pi)^{\frac{p+1}{2}} \sigma^{p+1}} \cdot \frac{1}{n} \sum_{i=1}^n \exp\left[-\frac{(\mathbf{X} - \mathbf{X}_i)^T(\mathbf{X} - \mathbf{X}_i)}{2\sigma^2}\right] \cdot \exp\left[-\frac{(y - y_i)^2}{2\sigma^2}\right] \, dy} \\
 &= \frac{\frac{1}{(2\pi)^{\frac{p+1}{2}} \sigma^{p+1}} \cdot \frac{1}{n} \sum_{i=1}^n \exp\left[-\frac{(\mathbf{X} - \mathbf{X}_i)^T(\mathbf{X} - \mathbf{X}_i)}{2\sigma^2}\right] \int_{-\infty}^{\infty} y \exp\left[-\frac{(y - y_i)^2}{2\sigma^2}\right] \, dy}{\frac{1}{(2\pi)^{\frac{p+1}{2}} \sigma^{p+1}} \cdot \frac{1}{n} \sum_{i=1}^n \exp\left[-\frac{(\mathbf{X} - \mathbf{X}_i)^T(\mathbf{X} - \mathbf{X}_i)}{2\sigma^2}\right] \int_{-\infty}^{\infty} \exp\left[-\frac{(y - y_i)^2}{2\sigma^2}\right] \, dy} \\
 &= \frac{\sum_{i=1}^n \exp\left[-\frac{(\mathbf{X} - \mathbf{X}_i)^T(\mathbf{X} - \mathbf{X}_i)}{2\sigma^2}\right] \int_{-\infty}^{\infty} y \exp\left[-\frac{(y - y_i)^2}{2\sigma^2}\right] \, dy}{\sum_{i=1}^n \exp\left[-\frac{(\mathbf{X} - \mathbf{X}_i)^T(\mathbf{X} - \mathbf{X}_i)}{2\sigma^2}\right] \int_{-\infty}^{\infty} \exp\left[-\frac{(y - y_i)^2}{2\sigma^2}\right] \, dy} \quad (3.3)
 \end{aligned}$$

dengan melakukan permisalan fungsi skalar D_i^2 sebagai

$$D_i^2 = (\mathbf{X} - \mathbf{X}_i)^T(\mathbf{X} - \mathbf{X}_i). \quad (3.4)$$

Setelah dilakukan integral, didapatkan persamaan

$$\hat{y}(\mathbf{X}) = \frac{\sum_{i=1}^n y_i \exp\left[-\frac{D_i^2}{2\sigma^2}\right]}{\sum_{i=1}^n \exp\left[-\frac{D_i^2}{2\sigma^2}\right]}. \quad (3.5)$$

3.1 Pembagian Data

Pembagian data merupakan salah satu proses yang dilakukan untuk membagi set data menjadi data *training* (pelatihan) dan data *testing* (pengujian). Data pelatihan digunakan untuk melakukan pengenalan pola data dan pembentukan model, sedangkan data pengujian digunakan untuk menguji model yang sudah terbentuk dengan melihat keakurasian hasil. Proses pembagian data perlu dilakukan, sebab, jika semua set data digunakan dalam pembentukan model,

maka model akan terjadi *overfitting* dan menghasilkan prediksi yang tidak akurat (Joseph & Vakayil, 2022).

3.2 Normalisasi dan Denormalisasi Data

Sebelum dilakukan proses GRNN, perlu ada tahapan *pre-processing*. Salah satu tahapan ini adalah dilakukannya normalisasi pada data-data yang ada dengan tujuan membuat semua variabel memiliki rentang nilai yang sama. Normalisasi ini penting ketika data yang memiliki rentang nilai yang sangat berbeda sehingga tidak ada dominasi dari variabel yang memiliki nilai besar. Contoh normalisasi yang dapat dilakukan adalah *Min Max Normalization*. *Min Max Normalization* akan menghasilkan nilai baru dengan rentang 0 sampai 1 (Deepa & Ramesh, 2022) menggunakan nilai maksimum dan nilai minimum dari masing-masing data dengan persamaan berikut:

$$x' = \frac{x - x_{min}}{x_{max} - x_{min}} \quad (3.6)$$

dengan x' merupakan nilai baru yang sudah dinormalisasi, x merupakan nilai asli dari data, x_{min} merupakan nilai minimum dari data, dan x_{max} merupakan nilai maksimum dari data.

Setelah proses analisis, *output* yang didapatkan akan memiliki nilai dengan rentang 0 sampai 1, sehingga perlu dilakukan denormalisasi untuk dapat menghasilkan nilai sesuai dengan data awal atau dengan kata lain menghasilkan nilai yang sebenarnya. Persamaan 3.7 merupakan denormalisasi dengan keterangan yang sama seperti pada normalisasi data.

$$x = x'(x_{max} - x_{min}) + x_{min}. \quad (3.7)$$

3.3 Pemilihan Parameter *Smoothing*

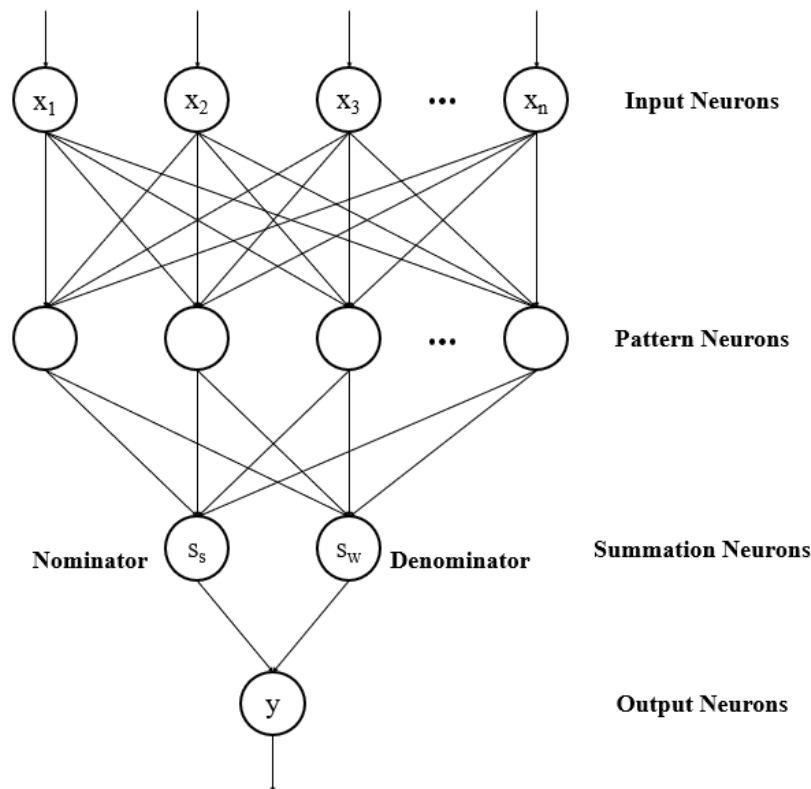
Setelah data dinormalisasi, estimasi kernel σ perlu dilakukan dengan metode pemilihan σ yang disebut metode *holdout*. Pada beberapa nilai σ , metode ini akan

menghapus satu sampel dan dilakukan konstruksi jaringan berdasarkan semua sampel lain. Lalu, jaringan tersebut akan mengestimasi Y untuk sampel yang telah dihapus. Dengan melakukan perulangan pada proses ini untuk setiap sampel dan dihasilkannya setiap estimasi, maka nilai kesalahan rata-rata kuadrat dapat diukur pada nilai sampel aktual Y dan estimasi.

Nilai σ yang terlalu besar akan membuat estimasi menjadi sangat halus sehingga tidak sesuai dengan pola data, tetapi jika nilai σ terlalu kecil juga akan membuat estimasi menjadi kasar dan sangat flukutatif (Hardle, 1994), sehingga nilai σ terbaik dapat ditentukan dengan melakukan *trial and error* pada masing-masing nilai yang diujikan (Zaknich & Attikiouzel, 1997). Nilai σ yang memiliki kesalahan terkecil akan digunakan pada jaringan terakhir.

3.4 Struktur dan Arsitektur GRNN

Secara struktur, GRNN memiliki 4 lapisan proses atau neuron (Specht, 1991).



Gambar 3.1 Arsitektur GRNN

1) *Input Neuron* (Neuron *Input*)

Input Neuron digunakan untuk menerima informasi. Pada lapisan ini data *input* dari masing-masing variabel prediktor akan diletakkan dan tidak ada proses apapun di neuron ini. Kemudian data dari neuron *input* akan ditransfer menuju neuron selanjutnya.

2) *Pattern Neuron* (Neuron Pola)

Pada neuron pola, dilakukan proses menggabungkan dan memproses data secara sistematis. Jumlah neuron pada lapisan ini adalah sejumlah data yang ada pada data *training*. Terdapat fungsi aktivasi untuk melakukan transfer sinyal jaringan pada lapisan ini, dimana fungsi aktivasi tersebut dapat dihitung hasilnya dengan menggunakan persamaan 3.8.

$$\theta_i = e^{\frac{-(X-X_i)^T(X-X_i)}{2\sigma^2}} \quad (3.8)$$

dengan X adalah vektor input pada variabel prediktor, X_i adalah vektor *training* yang diwakili oleh neuron pola i , dan σ adalah parameter *smoothing*.

3) *Summation Neuron* (Neuron Penjumlahan)

Setelah dari neuron pola, hasilnya akan diteruskan ke neuron penjumlahan. Pada neuron ini, terdapat dua jenis penjumlahan, yaitu penjumlahan aritmatika sederhana dan penjumlahan terboboti. Dua jenis penjumlahan ini dilakukan secara terpisah.

$$S_s = \sum_i \theta_i \quad (3.9)$$

$$S_w = \sum_i w_i \theta_i \quad (3.10)$$

dengan S_s merupakan penjumlahan aritmatika sederhana, S_w merupakan penjumlahan terboboti, w_i merupakan bobot yang berupa nilai variabel *output* pada data pelatihan, dan θ_i merupakan *output* yang didapatkan dari neuron pola.

4) *Output Neuron* (Neuron *Output*)

Neuron terakhir adalah neuron output, dimana pada neuron ini, terjadi pembagian antar penjumlahan dari neuron penjumlahan. Dari pembagian ini akan dihasilkan *output* y sebagai hasil GRNN dan ditunjukkan dengan persamaan berikut

$$y = \frac{S_w}{S_s}. \quad (3.11)$$


3.5 Proses Prediksi dengan GRNN

Dalam penelitian ini, GRNN dilakukan untuk memprediksi Indeks Saham Syariah Indonesia (ISSI). Proses GRNN untuk memprediksi terdiri dari beberapa tahapan proses yang perlu dilalui, antara lain

- 1) Data disiapkan terlebih dahulu, dalam hal ini, data yang digunakan adalah data *time series* ISSI, kurs jual, kurs beli, dan inflasi dari tanggal 3 Januari 2022 sampai dengan 31 Maret 2023.
- 2) Kemudian, dilakukan identifikasi *input* data masa lalu dari data ISSI dengan menggunakan lag pada *Partial Autocorrelation Function* (PACF). Dengan ini, input yang digunakan adalah data masa lalu ISSI, kurs jual, kurs beli, dan inflasi.
- 3) Data dibagi menjadi data *training* (pelatihan) dan data *testing* (pengujian). Pembagian menggunakan rasio 80% data *training* dan 20% data *testing*.
- 4) Setelah itu, tahapan normalisasi data kepada semua variabel yang digunakan.
- 5) Setelah variabel input dan output sudah ditetapkan serta data dibagi dan dinormalisasi, maka proses GRNN dapat dilakukan. Pengenalan pola GRNN

dilakukan dengan menggunakan data *training* dengan penggunaan nilai *spread* yang berbeda. Input akan masuk ke neuron input kemudian ke neuron pola yang jumlahnya sama dengan jumlah data *training*. Kemudian hasil akan diteruskan ke neuron penjumlahan. Setelah itu, hasil neuron penjumlahan akan dibagi dan menghasilkan *output* prediksi. Nilai *spread* terkecil akan digunakan dalam jaringan GRNN.

- 6) Proses pengujian dilakukan dengan menggunakan data *testing* dengan proses GRNN yang sama. Setelah prediksi dari data *testing* didapatkan, maka dilakukan uji kesalahan prediksi dengan menggunakan *Mean Absolute Error* (MAE) dan *Root Mean Squared Error* (RMSE).
- 7) Prediksi ISSI untuk beberapa hari ke depan.



Gambar 3.2 Tahapan prediksi dengan GRNN

BAB IV

STUDI KASUS

Pada bab ini, akan dibahas studi kasus tentang penerapan metode *General Regression Neural Network* untuk memprediksi harga terakhir Indeks Saham Syariah Indonesia. Bab ini terdiri dari deskripsi data, identifikasi input, uji korelasi, identifikasi input, pembagian data, normalisasi data, proses GRNN, perbandingan peramalan kedua input, dan prediksi untuk beberapa periode ke depan.

4.1 Deskripsi Data

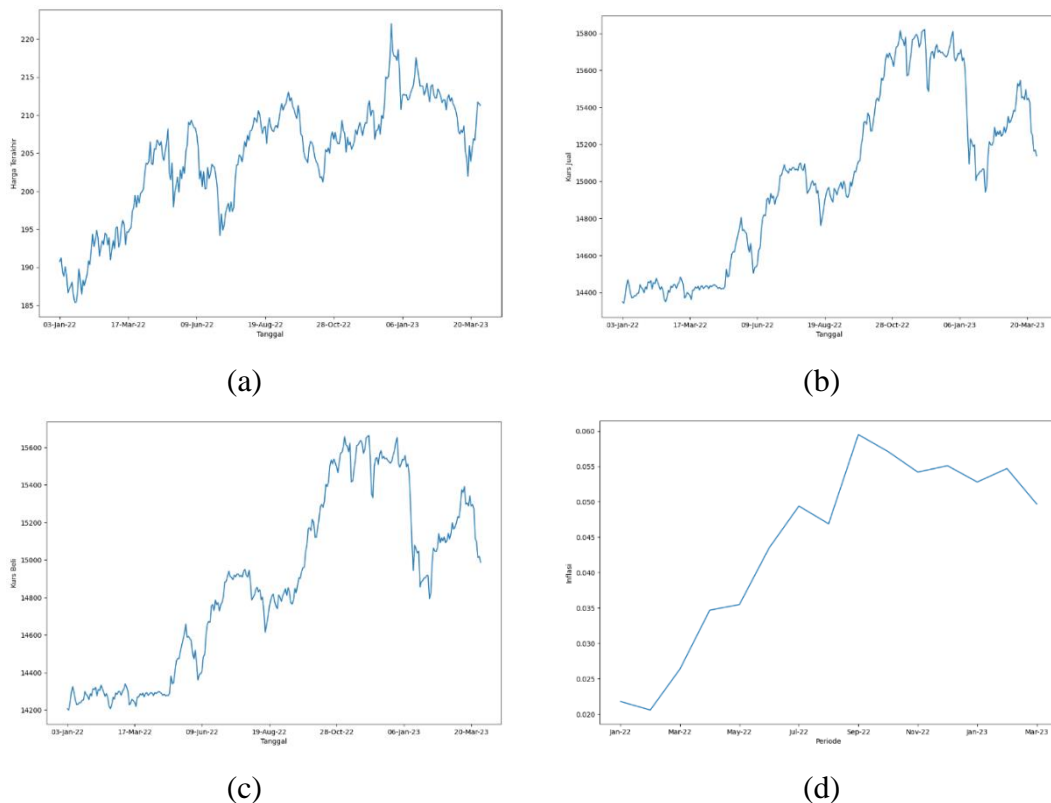
Data-data yang digunakan pada studi kasus adalah data harga terakhir Indeks Saham Syariah Indonesia, kurs jual, kurs beli, dan inflasi. Untuk data harga terakhir Indeks Saham Syariah Indonesia, diambil dari situs daring <https://id.investing.com/> sedangkan data kurs jual, kurs beli, dan inflasi diambil dari situs daring resmi Bank Indonesia secara harian dari tanggal 3 Januari 2022 sampai dengan 31 Maret 2023. Harga terakhir Indeks Saham Syariah Indonesia digunakan sebagai variabel output. Selain data masa lalu yang digunakan untuk menjadi variabel input, data kurs jual, kurs beli, dan inflasi juga akan digunakan sebagai variabel input yang akan memprediksi harga terakhir Indeks Saham Syariah Indonesia.

Tabel 4.1 Statistik dasar data

	Harga Terakhir ISSI	Kurs Jual	Kurs Beli	Inflasi
Max	222.00	15,820.71	15,663.29	0.0595
Min	185.35	14,341.35	14,198.65	0.0206
Rata-rata	204.53	15,020.20	14,870.74	0.0446
Median	206.30	15,009.17	14,859.83	0.0494
Std. deviasi	7.63	469.65	464.97	0.0126

Dari Gambar 4.1 (a), terlihat bahwa harga terakhir mengalami kenaikan dari waktu ke waktu hingga harga tertingginya ada pada tanggal 27 Desember 2022 atau data ke-243 dengan nilai Rp222.00, sedangkan harga terendah ada pada tanggal 18 Januari 2022 atau data ke-12 dengan nilai Rp185.35.

Data kurs jual, pada gambar 4.1 (b), dan kurs beli rupiah, pada gambar 4.1 (c) juga mengalami kenaikan nilai dengan nilai tertinggi keduanya ada pada data ke-225 atau tanggal 1 Desember 2022 dengan kurs jual sebesar Rp15,820.71 dan kurs beli sebesar Rp15,663.29. Untuk nilai terendah keduanya ada pada data ke-2 atau tanggal 4 Januari 2022 dengan kurs jual sebesar Rp14,341.35 dan kurs beli sebesar Rp14,198.65. Gambar 4.1 (d) menunjukkan Inflasi yang terjadi di Indonesia juga mengalami kenaikan dengan puncak tertinggi pada bulan September 2022 sebesar 5.95% dan terendah pada bulan Februari 2022 sebesar 2.06%.




Gambar 4.1 Plot *time series* data (a) harga ISSI, (b) kurs jual, (c) kurs beli, dan (d) inflasi

4.2 Uji Korelasi

Uji korelasi dilakukan untuk dapat melihat apakah ada hubungan dan seberapa kuat hubungan yang terjadi antar variabel. Dalam hal ini, ingin dilihat hubungan yang terjadi antara variabel *output* harga terakhir ISSI dan variabel-variabel *input*, yaitu kurs jual, kurs beli, dan inflasi.


Gambar 4.2 merupakan plot antara variabel harga terakhir ISSI dan kurs jual. Plot ini berfungsi untuk memudahkan analisa dalam melihat bagaimana hubungan kedua variabel, contohnya apakah semakin tinggi nilai kurs jual juga akan membuat harga terakhir ISSI semakin tinggi juga. Terlihat bahwa dari plot menunjukkan bahwa kurs jual yang tinggi juga memiliki harga terakhir ISSI yang tinggi. Seperti contohnya, harga terakhir sebesar Rp222.00 yang merupakan data nilai harga tertinggi ISSI memiliki nilai kurs jual sebesar Rp15,714.18, nilai kurs jual yang tinggi.



Gambar 4.2 Scatterplot hubungan harga terakhir ISSI dan kurs jual


Selanjutnya pada gambar 4.3 merupakan *scatterplot* antara variabel harga terakhir ISSI dan variabel kurs beli. Plot yang dihasilkan hampir sama dengan plot hubungan harga terakhir ISSI dan variabel kurs jual. Harga terakhir yang tinggi

juga memiliki nilai kurs beli yang tinggi, begitupun sebaliknya, sehingga disimpulkan bahwa hubungan kedua variabel bersifat positif.



Gambar 4.3 Scatterplot hubungan harga terakhir ISSI dan kurs beli

Scatterplot pada gambar 4.4 menunjukkan hubungan antara variabel harga terakhir ISSI dan nilai inflasi. Inflasi yang diambil merupakan inflasi perbulan, sehingga pada plot ini terdapat 15 titik nilai inflasi, yang menunjukkan bahwa waktu data yang diambil sebanyak 15 bulan, mulai dari bulan Januari 2022 hingga Maret 2023. Terlihat bahwa semakin besar nilai inflasi yang terjadi, maka nilai harga terakhir ISSI juga semakin tinggi. Inflasi yang kurang dari 3% memiliki harga terakhir ISSI dengan rentang Rp185.00 hingga Rp200.00. Berbeda dengan inflasi yang lebih dari 5% memiliki harga terakhir ISSI di atas Rp200.00. Dengan ini dapat dikatakan bahwa kedua variabel ini, variabel harga terakhir ISSI dan variabel inflasi, memiliki hubungan yang positif.



Gambar 4.4 *Scatterplot* hubungan harga terakhir ISSI dan inflasi

Hubungan antar variabel selain dari plot, juga dapat dilihat dari koefisien korelasi dan p-value-nya. Hipotesis awal yang digunakan adalah bahwa tidak terdapat hubungan antara harga terakhir ISSI dengan kurs jual, kurs beli, ataupun inflasi. Nilai P-Value yang dihasilkan pada hubungan antara harga terakhir ISSI dengan kurs jual, kurs beli, dan inflasi adalah sebesar 0.000. Dengan tingkat kepercayaan sebesar 95%, maka disimpulkan bahwa terdapat hubungan antara harga terakhir ISSI dan kurs jual, harga terakhir ISSI dan kurs beli, serta antara harga terakhir ISSI dan inflasi.

Koefisien korelasi menunjukkan seberapa kuat hubungan yang terjadi antar variabel. Koefisien korelasi yang mendekati 1 menunjukkan bahwa kedua variabel memiliki hubungan yang positif, jika koefisien korelasi mendekati -1, maka kedua variabel memiliki hubungan yang negatif, dan jika koefisien korelasi bernilai 0, maka disimpulkan bahwa tidak terdapat hubungan antar kedua variabel.

Didapatkan bahwa koefisien korelasi antara harga terakhir dan kurs jual serta harga terakhir dan kurs beli sebesar 0.62320, sehingga hubungan yang terjadi merupakan hubungan kuat secara positif. Begitu pula untuk harga terakhir ISSI dan inflasi, koefisien korelasi yang dihasilkan adalah sebesar 0.70477, yang


menunjukkan bahwa hubungan antara keduanya adalah hubungan kuat yang positif.

Tabel 4.2 Uji korelasi variabel output dan variabel-variabel input

	Koefisien Korelasi	P-Value
Harga & Kurs Jual	0.62320	0.000
Harga & Kurs Beli	0.62320	0.000
Harga & Inflasi	0.70477	0.000

4.3 Identifikasi Input

Identifikasi input dilakukan dengan melihat data masa lalu atau *lag time*, dimana lag ini didasarkan oleh nilai *Partial Autocorrelation Function* (PACF) terbesar. Hal ini karena karakteristik persamaan model yang dimiliki oleh GRNN memiliki kesamaan pada model *Autoregressive* (AR) (Caraka, Yasin, & Prahutama, 2015).



Gambar 4.5 Plot *Partial Autocorrelation Function* (PACF)

Dari identifikasi lag yang dilakukan pada data *time series* harga terakhir ISSI, didapatkan bahwa plot PACF, gambar 4.5, menunjukkan bahwa lag 1

melewati daerah kepercayaan 95%. Daerah kepercayaan dihitung dari rumus *confidence interval* atau interval kepercayaan $CI = \pm \frac{Z_{\alpha/2}}{\sqrt{n}}$. Dengan kepercayaan 95% dan n merupakan jumlah observasi sebanyak 308 data, maka didapatkan bahwa $CI = \pm 0.11168$, dimana PACF yang berada di luar interval tersebut menandakan bahwa lag tersebut memiliki autokorelasi yang signifikan terhadap periode saat ini dan dijadikan sebagai acuan identifikasi input dalam proses prediksi. Lag 1 memiliki PACF sebesar 0.97326, lebih besar dari interval atau berada di luar daerah interval kepercayaan. Oleh karena itu, dapat dikatakan bahwa harga terakhir ISSI periode ke- t (X_t) dipengaruhi oleh harga terakhir ISSI satu periode sebelumnya (X_{t-1}).

Tabel 4.3 Partial Autocorrelation Function harga terakhir ISSI

Lag	PACF	Lag	PACF	Lag	PACF	Lag	PACF	Lag	PACF
1	0.9733	6	-0.0018	11	-0.0586	16	-0.0307	21	0.0396
2	0.0844	7	-0.0329	12	0.0330	17	-0.0395	22	0.0115
3	-0.0043	8	0.0238	13	0.0329	18	-0.0377	23	-0.0356
4	-0.0803	9	0.0181	14	-0.0424	19	0.0020	24	0.0628
5	-0.0157	10	0.0511	15	0.0974	20	-0.0724	25	-0.0138

4.4 Pembagian Data

Setelah itu, dilakukan *splitting data* atau pembagian data menjadi data *training* (pelatihan) dan data *testing* (pengujian) dengan *library train test split*. Pada studi kasus ini, pembagian 307 data dilakukan dengan membagi menjadi 80% data pelatihan dan 20% data pengujian dengan rincian sebagai berikut:

Tabel 4.4 Pembagian data

	Persentase	Jumlah
Data pelatihan	80%	245
Data pengujian	20%	62
Total	100%	307

4.5 Normalisasi Data

Semua data yang akan digunakan, yaitu data harga terakhir, kurs jual, kurs beli, dan inflasi, perlu dilakukan normalisasi terlebih dahulu dengan menggunakan *min-max normalization* agar data-data tersebut memiliki rentang nilai yang sama. *Min-Max Normalization* dilakukan dengan menggunakan persamaan 3.6. Hasil dari normalisasi data pelatihan terdapat pada Lampiran 4 dan data pengujian pada Lampiran 5.

4.6 GRNN dengan Input Data Masa Lalu

Pada studi kasus pertama, input data yang digunakan untuk melakukan prediksi harga terakhir Indeks Saham Syariah Indonesia adalah data masa lalu. Proses GRNN diawali dengan melakukan identifikasi input untuk mengetahui harga masa lalu yang digunakan sebagai input dan berhubungan dengan harga masa sekarang, lalu pembagian data, dan dilakukan proses GRNN dengan menghasilkan hasil prediksi pada data *test*, nilai kesalahan prediksi, serta plot perbandingan antara harga aktual dan harga prediksi.

Proses GRNN dilakukan dengan menggunakan variabel input dan variabel output pada data *training* variabel harga terakhir ISSI sebagai nilai *output* dan variabel data masa lalu sebagai nilai *input* dengan fungsi *algorithms.GRNN*. Variabel input akan masuk ke dalam *layer* pertama, yaitu *input neuron* (neuron input). Pada *layer* ini, tidak ada proses data. Kemudian dari neuron input, data ditransfer ke *layer* kedua untuk diproses yang bernama *pattern neuron* (neuron pola). Pada neuron ini, dibangun output θ yang dihitung dengan persamaan 3.8. Output-output tersebut kemudian dilanjutkan ke *layer* ketiga, yaitu *summation neuron* (neuron penjumlahan), untuk dijumlahkan. Neuron penjumlahan terdiri dari dua jenis, yaitu penjumlahan aritmatika sederhana dan penjumlahan terboboti dengan masing-masing perhitungannya pada persamaan 3.9 dan 3.10. Setelah dijumlahkan, neuron-neuron tersebut dikirim ke *layer* keempat untuk diproses, yang disebut *output neuron* (neuron output). Hasil dari neuron output merupakan pembagian dari penjumlahan terboboti dan penjumlahan aritmatika sederhana yang dilakukan pada *layer* ketiga.

Tabel 4.5 Hasil percobaan *spread* input masa lalu

<i>Spread</i>	MAE	RMSE	<i>Spread</i>	MAE	RMSE
0.05	1.40607	1.75040	0.30	4.72257	5.14916
0.10	2.08962	2.34890	0.35	5.17978	5.63230
0.15	2.95027	3.25686	0.40	5.59682	6.07593
0.20	3.66058	4.02350	0.45	5.98320	6.47410
0.25	4.22543	4.62461	0.50	6.32302	6.82369

Untuk mengetahui hasil yang optimal pada proses GRNN, maka dilakukan percobaan pada 10 nilai *spread*, yaitu 0.05, 0.10, 0.15, 0.20, 0.25, 0.30, 0.35, 0.40, 0.45, dan 0.50, yang kemudian didapatkan bahwa nilai kesalahan prediksi terkecil ada pada *spread* 0.05. Semakin besar nilai *spread*, nilai kesalahan prediksi yang dihasilkan semakin besar. Hasil perbandingan tiap *spread* terdapat pada tabel 4.5. Oleh karena itu, prediksi harga terakhir ISSI yang akan digunakan adalah prediksi yang menggunakan GRNN dengan *spread* 0.05 dan hasil prediksi pada tabel 4.6.


Tabel 4.6 Hasil prediksi data *test* input data masa lalu

No.	Tanggal	Aktual	Prediksi	No.	Tanggal	Aktual	Prediksi
1	2-Jan-23	217.18	218.90	6	9-Jan-23	212.74	211.38
2	3-Jan-23	218.60	218.58	7	10-Jan-23	212.62	211.53
3	4-Jan-23	215.76	218.96	8	11-Jan-23	212.66	211.43
4	5-Jan-23	210.75	216.48	9	12-Jan-23	211.96	211.46
5	6-Jan-23	212.57	209.94	10	13-Jan-23	212.14	210.91

Setelah hasil prediksi didapatkan dengan metode GRNN, pengujian dilakukan untuk melihat seberapa besar kesalahan (*error*) yang dihasilkan prediksi. Ukuran yang digunakan adalah *Mean Absolute Error* (MAE) dan *Root Mean Squared Error* (RMSE). MAE merupakan ukuran kesalahan yang menggunakan rata-rata nilai absolut dari semua *error* prediksi dan RMSE merupakan ukuran kesalahan yang menggunakan akar dari rata-rata nilai kuadrat semua *error* prediksi.

MAE dari prediksi harga terakhir ISSI sebesar 1.40607 dan RMSE yang didapatkan sebesar 1.75040. Dengan nilai-nilai ini, disimpulkan bahwa proses GRNN untuk prediksi harga terakhir ISSI dengan input data masa lalu sudah baik untuk digunakan.

Gambar 4.6 menunjukkan perbandingan nilai aktual dan prediksi proses GRNN yang dilakukan dengan input data masa lalu, nilai aktual dipresentasikan dengan garis berwarna biru dan nilai prediksi dipresentasikan dengan garis berwarna oranye. Terlihat bahwa nilai prediksi harga terakhir ISSI yang dihasilkan GRNN sudah hampir menyerupai nilai aktual harga terakhir ISSI. Pergerakan dari nilai prediksi juga sama dengan pergerakan nilai aktual. Dari grafik perbandingan ini, dapat disimpulkan bahwa GRNN mampu untuk memprediksi harga terakhir dengan baik dan hasilnya mendekati nilai aktualnya dengan nilai kesalahan yang cukup kecil.



Gambar 4.6 Perbandingan harga aktual dan prediksi menggunakan input masa lalu

4.7 GRNN dengan Input Kurs Jual, Kurs Beli, dan Inflasi

Selanjutnya pada studi kasus kedua, prediksi harga ISSI dilakukan dengan menggunakan tambahan variabel input dari nilai kurs jual, kurs beli, dan Inflasi. Kurs jual dan beli merupakan nilai tukar rupiah terhadap dollar Amerika. Diawali dengan uji korelasi untuk melihat apakah ada hubungan antar variabel, kemudian pembagian data menjadi data *train* dan *data test*, lalu dilakukan normalisasi data input agar data-data tersebut memiliki rentang nilai yang sama, dilanjutkan dengan proses GRNN, selanjutnya didapatkan hasil prediksi dari data *test*, nilai kesalahan prediksi, dan disajikan plot perbandingan antara harga aktual dan harga prediksi.

Proses GRNN dapat dilakukan dengan data *training* pada variabel output harga terakhir ISSI dan variabel-variabel input data masa lalu, kurs jual, kurs beli, dan inflasi. Variabel-variabel input masuk ke neuron input, dimana pada *layer* ini tidak ada proses apapun. Dari neuron input, data masuk ke neuron pola untuk dihasilkan output θ . Output-output tersebut kemudian dilanjutkan ke neuron penjumlahan, untuk dijumlahkan secara penjumlahan aritmatika sederhana dan penjumlahan terboboti. Selanjutnya, hasil dari neuron penjumlahan akan masuk ke neuron output untuk diproses menghasilkan output yang diinginkan dengan membagi penjumlahan terboboti dengan penjumlahan aritmatika sederhana.

Tabel 4.7 Hasil percobaan *spread* input kurs jual, kurs beli, dan inflasi

<i>Spread</i>	MAE	RMSE	<i>Spread</i>	MAE	RMSE
0.05	3.21308	3.78867	0.30	4.28128	4.77254
0.10	3.25403	3.79735	0.35	4.48928	5.00766
0.15	3.51548	3.95488	0.40	4.65807	5.19717
0.20	3.77520	4.20755	0.45	4.79894	5.35292
0.25	4.03122	4.49488	0.50	4.92464	5.48964

Dengan melihat perbandingan nilai kesalahan prediksi pada setiap nilai *spread* yang di uji, pada proses GRNN dengan tambahan input kurs jual, kurs beli, dan inflasi, didapatkan bahwa semakin besar nilai *spread* yang digunakan, maka


nilai kesalahan prediksi juga akan semakin besar. Dengan ini, proses GRNN yang optimal adalah nilai *spread* sebesar 0.05, karena memiliki nilai kesalahan prediksi terkecil dalam melakukan prediksi pada harga terakhir ISSI. Tabel 4.7 menunjukkan nilai kesalahan masing-masing *spread* yang digunakan dan tabel 4.8 adalah tabel prediksi harga terakhir ISSI yang didapatkan pada data *test*.

Tabel 4.8 Hasil prediksi data *test* input kurs jual, kurs beli, dan inflasi

No.	Tanggal	Aktual	Prediksi	No.	Tanggal	Aktual	Prediksi
1	2-Jan-23	217.18	219.65	6	9-Jan-23	212.74	212.16
2	3-Jan-23	218.60	217.62	7	10-Jan-23	212.62	213.67
3	4-Jan-23	215.76	221.04	8	11-Jan-23	212.66	213.19
4	5-Jan-23	210.75	216.63	9	12-Jan-23	211.96	213.45
5	6-Jan-23	212.57	209.94	10	13-Jan-23	212.14	210.44

Ukuran kesalahan (*error*) menggunakan *Mean Absolute Error* (MAE) dan *Root Mean Squared Error* (RMSE). Dari prediksi harga terakhir ISSI dengan input kurs jual, kurs beli, dan inflasi didapatkan MAE sebesar 3.21308 dan RMSE sebesar 3.78867. Nilai MAE dan RMSE ini menyimpulkan bahwa proses GRNN sudah baik dan dapat digunakan untuk memprediksi harga terakhir ISSI menggunakan tambahan input kurs jual, kurs beli, dan inflasi.

Gambar 4.7 menunjukkan perbandingan antara nilai aktual harga terakhir ISSI dan nilai prediksinya dengan input kurs jual, kurs beli, dan inflasi. Walaupun harga prediksi masih jauh dari nilai harga aktual, tetapi pergerakan yang dihasilkan harga prediksi sudah hampir menyerupai harga aktual. Dengan ini, input kurs jual, kurs beli, dan juga inflasi dapat dengan baik melakukan prediksi terhadap harga terakhir ISSI dengan menggunakan metode GRNN.



Gambar 4.7 Plot perbandingan harga aktual dan prediksi menggunakan input kurs jual, kurs beli, dan inflasi

4.8 Perbandingan

Untuk mengetahui input yang lebih baik dalam memprediksi harga terakhir ISSI dengan menggunakan metode GRNN, perlu dilihat nilai ukuran kesalahan pada kedua input. Input pertama merupakan data masa lalu harga terakhir ISSI dan input kedua merupakan kurs jual, kurs beli, dan inflasi. Ukuran kesalahan tercantum pada tabel 4.9.

Tabel 4.9 Uji kesalahan prediksi


	Input 1	Input 2
MAE	1.40607	3.21308
RMSE	1.75040	3.78867

Didapatkan pada input pertama, MAE sebesar 1.40607 nilainya lebih kecil dari MAE input kedua sebesar 3.21308. Begitu pula dengan RMSE yang didapatkan pada input pertama adalah sebesar 1.75040, dimana nilai ini lebih kecil

daripada RMSE input kedua sebesar 3.78867. Oleh karena itu, dapat disimpulkan bahwa GRNN dengan input data masa lalu lebih baik digunakan untuk melakukan prediksi pada harga terakhir ISSI.

Plot pada gambar 4.8 menunjukkan perbandingan hasil prediksi harga dari kedua input dan harga aktual. Harga aktual ditunjukkan oleh garis berwarna biru, harga prediksi input pertama ditunjukkan oleh garis berwarna oranye, dan harga prediksi input kedua ditunjukkan oleh garis berwarna hijau. Harga prediksi input pertama pergerakannya lebih menyerupai dengan harga aktual dibandingkan dengan harga prediksi input kedua.

Dengan ini dapat disimpulkan bahwa input pertama, yaitu input data masa lalu, merupakan input yang lebih baik untuk digunakan untuk melakukan prediksi harga terakhir ISSI menggunakan metode GRNN pada beberapa periode ke depan.



Gambar 4.8 Plot perbandingan harga aktual dan prediksi

4.9 Prediksi untuk Empat Periode Ke Depan

Prediksi harga terakhir ISSI menggunakan metode GRNN untuk empat periode ke depan, yaitu tanggal 3 hingga 6 April 2023, dengan input data masa lalu dan ditambah dengan faktor makroekonomi.

Input data masa lalu

Pada input ini, proses GRNN akan menggunakan *spread* atau parameter *smoothing* sebesar 0.05, sebab nilai tersebut memiliki nilai kesalahan paling kecil setelah diuji menggunakan data pelatihan dan data pengujian. Prediksi dengan input masa lalu akan menggunakan data satu periode sebelumnya dari periode yang akan diprediksi. Dengan ini, untuk prediksi tanggal 3 April 2023 akan menggunakan harga terakhir ISSI pada tanggal 31 Maret 2023 sebesar Rp211.27 dengan hasil normalisasi sebesar 0.707231.

Proses diawali dengan mencari nilai θ pada lapisan pola (*pattern neuron*) menggunakan persamaan 3.8 dengan $(X - X_i)^T = (X - X_i)$, sehingga:

$$\begin{aligned}\theta_1 &= e^{-\frac{(0.707231-0.14761)^2}{2(0.05)^2}} = 6.2835 \times 10^{-28} \\ \theta_2 &= e^{-\frac{(0.707231-0.15989)^2}{2(0.05)^2}} = 9.5224 \times 10^{-27} \\ &\vdots \\ \theta_{245} &= e^{-\frac{(0.707231-0.88486)^2}{2(0.05)^2}} = 1.8176 \times 10^{-3}.\end{aligned}$$

Setelah itu, proses dilanjutkan ke lapisan penjumlahan (*summation neuron*) dengan menggunakan persamaan 3.9 untuk penjumlahan aritmatika sederhana dan 3.10 untuk penjumlahan terboboti.

$$\begin{aligned}S_s &= \sum_{i=1}^{245} \theta_i = 6.2835 \times 10^{-28} + 9.5224 \times 10^{-27} + \dots + 1.8176 \times 10^{-3} \\ &= 37.99264\end{aligned}$$

dan

$$\begin{aligned}
S_w &= \sum_{i=1}^{245} w_i \theta_i \\
&= (0.15989 \times 6.2835 \times 10^{-28}) + (0.10941 \times 9.5224 \times 10^{-27}) + \dots \\
&\quad + (0.88349 \times 1.8176 \times 10^{-3}) \\
&= 25.40023.
\end{aligned}$$

Setelah didapatkan hasil untuk lapisan penjumlahan, maka akan dihitung hasil prediksi dengan menggunakan persamaan 3.11.

$$y = \frac{S_w}{S_s} = \frac{25.40023}{37.99264} = 0.66856.$$

Hasil tersebut merupakan nilai yang masih dinormalisasi, sehingga dilakukan denormalisasi agar mendapatkan nilai yang sesuai dengan data asli. Denormalisasi data menggunakan persamaan 3.7. Oleh karena itu, hasil prediksi untuk tanggal 3 April adalah sebesar 209.85260. Untuk prediksi harga terakhir ISSI pada tanggal 4 hingga 6 April 2023 dilakukan cara yang sama dan hasil prediksi terdapat pada tabel 4.10.

Tabel 4.10 Hasil prediksi dengan input data masa lalu

Tanggal	Prediksi
3 April 2023	209.85260
4 April 2023	208.89151
5 April 2023	208.28029
6 April 2023	207.90064

Input faktor makroekonomi

Untuk proses GRNN dengan tambahan input faktor makroekonomi juga menggunakan nilai *spread* sebesar 0.05, sesuai dengan hasil GRNN data pelatihan dan data pengujian. Dengan ini, input yang akan digunakan adalah data masa lalu, kurs jual, kurs beli, dan inflasi pada masing-masing tanggal yang ingin diprediksi.

Pertama, akan diproses lapisan pola dengan menghitung θ untuk prediksi tanggal 3 April 2023 menggunakan persamaan 3.8 dengan $(X - X_i)^T = (X - X_i)$, sehingga:

$$\begin{aligned}\theta_1 &= e^{-\frac{(0.707231-0.14761)^2+(0.48030-0.14761)^2+(0.48030-0.14761)^2+(0.58355-0.14761)^2}{2(0.05)^2}} \\ &= 1.1600 \times 10^{-63} \\ \theta_2 &= e^{-\frac{(0.707231-0.15989)^2+(0.48030-0.15989)^2+(0.48030-0.15989)^2+(0.58355-0.15989)^2}{2(0.05)^2}} \\ &= 3.5874 \times 10^{-60} \\ &\vdots \\ \theta_{245} &= e^{-\frac{(0.707231-0.88486)^2+(0.48030-0.88486)^2+(0.48030-0.88486)^2+(0.58355-0.88486)^2}{2(0.05)^2}} \\ &= 8.7488 \times 10^{-40}.\end{aligned}$$

Kemudian, proses pada lapisan penjumlahan untuk menghitung penjumlahan aritmatika sederhana dan penjumlahan terboboti menggunakan persamaan 3.9 dan persamaan 3.10.

$$\begin{aligned}S_s &= \sum_{i=1}^{245} \theta_i = 1.1600 \times 10^{-63} + 3.5874 \times 10^{-60} + \dots + 8.7488 \times 10^{-40} \\ &= 0.03625\end{aligned}$$

dan

$$\begin{aligned}S_w &= \sum_{i=1}^{245} w_i \theta_i \\ &= (0.15989 \times 1.1600 \times 10^{-63}) + (0.10941 \times 3.5874 \times 10^{-60}) + \dots \\ &\quad + (0.88349 \times 8.7488 \times 10^{-40}) \\ &= 0.02071.\end{aligned}$$

Lalu tahap terakhir, dihitung hasil prediksi dengan membagi penjumlahan terboboti dan penjumlahan aritmatika sederhana menggunakan persamaan 3.11.

$$y = \frac{S_w}{S_s} = \frac{0.02071}{0.03625} = 0.57114.$$

Setelah didenormalisasi dengan persamaan 3.7, hasil prediksi untuk tanggal 3 April dengan input yang ditambah dengan faktor makroekonomi adalah sebesar 206.28227. Dengan cara yang sama, maka untuk prediksi pada tanggal 4 hingga 6 April 2023 tertera pada tabel 4.11.

Tabel 4.11 Hasil prediksi dengan input kurs jual, kurs beli, dan inflasi

Tanggal	Prediksi
3 April 2023	206.28227
4 April 2023	206.34654
5 April 2023	205.69999
6 April 2023	205.84449

BAB V

PENUTUP

5.1 Kesimpulan

Penelitian dilakukan untuk menerapkan metode *General Regression Neural Network* (GRNN) dalam melakukan prediksi pada harga terakhir Indeks Saham Syariah Indonesia (ISSI). Data yang digunakan adalah data harga terakhir ISSI, kurs jual terhadap dollar Amerika, kurs beli terhadap dollar Amerika, dan inflasi secara harian dari tanggal 3 Januari 2022 hingga 31 Maret 2023. Input dalam memprediksi berupa input dari data masa lalu harga terakhir ISSI, dan input eksternal yang memiliki hubungan dengan Indeks Saham Syariah Indonesia, yaitu berupa data kurs jual, kurs beli, dan inflasi.

Kesimpulan yang didapatkan dalam penelitian ini, antara lain:

1. Metode GRNN dapat melakukan proses peramalan dalam memprediksi harga terakhir ISSI, baik dengan menggunakan input data masa lalu harga terakhir ISSI ataupun dengan tambahan input eksternal berupa kurs jual, kurs beli, dan inflasi. Pada input data data masa lalu, didapatkan nilai kesalahan prediksi harga terakhir ISSI sebesar 1.40607 untuk nilai *Mean Absolute Error* (MAE) dan 1.75040 untuk nilai *Root Mean Squared Error* (RMSE). Sedangkan pada input kurs jual, kurs beli, dan inflasi mendapatkan nilai kesalahan prediksi harga terakhir ISSI sebesar 3.21308 untuk nilai MAE dan 3.78867 untuk nilai RMSE.
2. Dari nilai kesalahan prediksi yang didapatkan, prediksi harga terakhir ISSI dengan input data masa lalu memiliki nilai kesalahan yang lebih kecil dibandingkan dengan prediksi harga terakhir ISSI dengan menggunakan input kurs jual, kurs beli, dan inflasi, baik nilai MAE maupun nilai RMSE. Oleh karena itu, input data masa lalu merupakan input terbaik untuk digunakan dalam melakukan prediksi harga terakhir ISSI dengan menggunakan GRNN.
3. Prediksi harga terakhir ISSI dengan menggunakan GRNN dengan input terbaik, yaitu input data masa lalu, adalah sebesar Rp209.85260,

Rp208.89151, Rp208.28029, dan Rp207.90064 secara berturut-turut dari tanggal 3 April hingga 6 April 2023.

5.2 Saran

Saran yang dapat diberikan dari penelitian ini antara lain:

1. Penggunaan GRNN dalam memprediksikan harga terakhir ISSI untuk keperluan investasi dapat hanya menggunakan input data masa lalu harga terakhir ISSI tanpa perlu melihat faktor eksternal.
2. Pada penelitian selanjutnya, dapat menambahkan input-input eksternal lain yang berhubungan dengan ISSI untuk meningkatkan hasil prediksi dan menjadi lebih akurat.
3. Dapat membandingkan GRNN dengan metode lain, baik *neural network* atau metode peramalan klasik untuk melihat performa dari metode GRNN.

DAFTAR PUSTAKA

- Achyar, G., & Rohaeni, O. (2022). Penggunaan Hybrid K-Means dan General Regression Neural Network untuk Prediksi Harga Saham Indeks LQ45. *Jurnal Riset Matematika*, 2(2), 111–120.
- Adnyani, L. P. W., & Subanar. (2015). General Regression Neural Network (GRNN) pada Peramalan Kurs Dolar Dan Indeks Harga Saham Gabungan (IHSG). *Faktor Exacta*, 8(2), 137–144.
- Algifari. (1997). *Analisis Statistik untuk Bisnis dengan Regresi, Korelasi, dan Nonparametrik*. Yogyakarta: BPFE-Yogyakarta.
- Andayani, M. (2021). Analisis Pengaruh Faktor-Faktor Makroekonomi Terhadap Indeks Harga Saham Gabungan Di Bursa Efek Indonesia Tahun 2015-2019. *Jurnal Ilmiah Mahasiswa FEB Universitas Brawijaya*.
- Assauri, S. (1984). *Teknik dan Metode Peramalan: Penerapannya dalam Ekonomi & Dunia Usaha*. Jakarta: Lembaga Penerbit Fakultas Ekonomi UI.
- Bank Indonesia. (2020). Inflasi. Diakses pada 2 Juni 2023, dari <https://www.bi.go.id/id/fungsi-utama/moneter/inflasi/Default.aspx>.
- Bursa Efek Indonesia. (2022). Indeks Saham Syariah. Diakses pada 31 Mei 2023, dari <https://www.idx.co.id/id/idx-syariah/indeks-saham-syariah>.
- Bursa Efek Indonesia. (2022). Indeks. Diakses pada 2 Juni 2023, dari <https://www.idx.co.id/id/produk/indeks>.
- Bursa Efek Indonesia. (2021). *Kinerja Pasar Modal Syariah Tahun 2021*. Jakarta.
- Bursa Efek Indonesia. (2022). *Kinerja Pasar Modal Syariah Q4 2022*. Jakarta.
- Caraka, R. E., Yasin, H., & Prahutama, A. (2014). Pemodelan General Regression Neural Network (GRNN) dengan Peubah Input Data Return untuk Peramalan Indeks Hangseng. *Seminar Nasional Ilmu Komputer*, 283–288.
- Caraka, R. E., Yasin, H., & Prahutama, A. (2015). Pemodelan General Regression Neural Network (GRNN) pada Data Return Indeks Harga Saham Euro 50. *Jurnal Gaussian*, 4(2), 181–192.
- Deepa, B., & Ramesh, K. (2022). Epileptic seizure detection using deep learning through min max scaler normalization. *International journal of health*

- sciences*, 6, 10981–10996.
- Halim, A. (2003). *Analisis Investasi*. Jakarta: Salemba Empat.
- Hanke, J. E., & Wichern, D. W. (2005). *Business Forecasting, 8th Edition*. New Jersey: Prentice Hall.
- Hardle, W. (1994). *Applied Nonparametric Regression*. New York: Cambridge University Press.
- Hermawan, A. (2006). *Jaringan Saraf Tiruan: Teori dan Aplikasi*. Yogyakarta: Andi.
- Joseph, V. R., & Vakayil, A. (2022). SPlit: An Optimal Method for Data Splitting. *Technometrics*, 64(2), 166–176.
- Junaidi, A., Wibowo, M. G., & Hasni. (2021). Pengaruh Variabel Ekonomi Makro Terhadap Indeks Saham Syariah Indonesia (ISSI) Periode Tahun 2014-2019. *Jurnal Ekonomi dan Bisnis*, 24(1), 17–29.
- Leung, M. T., Chen, A. S., & Daouk, H. (2000). Forecasting exchange rates using general regression neural networks. *Computers and Operations Research*, 27(11–12), 1093–1110.
- Moechdie, A. H., & Ramelan, H. (2012). *Gerbang Pintar Pasar Modal: Bukunya Investor & Profesional Pasar Modal Indonesia*. Jakarta: Capital Bridge Advisory.
- Muklis, F. (2016). Perkembangan dan Tantangan Pasar Modal Indonesia. *Al-Masraf: Jurnal Lembaga Keuangan dan Perbankan*, 1(1), 65–76.
- Otoritas Jasa Keuangan. (2015). *Peraturan Otoritas Jasa Keuangan Nomor 15/POJK.04/2015 tentang Penerapan Prinsip Syariah di Pasar Modal*. Jakarta.
- Pandey, P. (2022). Vector Norms: A Quick Guide. Diakses pada 12 Juli 2023, dari <https://builtin.com/data-science/vector-norms>.
- Pasaribu, R. B. F., & Firdaus, M. (2013). Analisis Pengaruh Variabel Makroekonomi Terhadap Indeks Saham Syariah Indonesia. *Jurnal Ekonomi & Bisnis*, 7(2), 117–128.
- Puspitaningrum, D. (2006). *Pengantar Jaringan Saraf Tiruan*. Yogyakarta: Andi.
- Rahayuningtyas, E. F., Wicaksono, G. W., & Chandranegara, D. R. (2021).

- Prediction of Yuan to IDR Exchange Rate using General Regression Neural Network. *2021 International Conference on Computer Science, Information Technology, and Electrical Engineering, ICOMITEE 2021*, 1–6.
- Rosadi, D. (2021). *Analisis Runtun Waktu dan Aplikasinya dengan R*. Yogyakarta: UGM Press.
- Sammut, C., & Webb, G. I. (Ed.). (2011). *Encyclopedia of Machine Learning*. Springer Science & Business Media.
- Sari, K. (2017). *Ruang Lingkup Ekonomi Makro*. Klaten: Cempaka Putih.
- Sitamahalakshmi, T., Babu, A. V., Jagadeesh, M., & Mouli, K. V. V. C. (2011). *Performance Comparison of Radial Basis Function Networks and Probabilistic Neural Networks for Telugu Character Recognition*. *11*(4), 9–16.
- Sjahrir. (1995). *Analisis Bursa Efek*. Jakarta: Jakarta Gramedia Pustaka Utama.
- Sofyan, D. K. (2013). *Perencanaan & Pengendalian Produksi*. Yogyakarta: Graha Ilmu.
- Specht, D. F. (1991). A General Regression Neural Network. *IEEE Transactions On Neural Networks*, *2*(6).
- Suciningtias, S. A., & Khoiroh, R. (2015). Analisis Dampak Variabel Makro Ekonomi Terhadap Indeks Saham Syariah Indonesia (ISSI). *Conference In Business Accounting and Management*, *2*(1), 398–412.
- Wiriani, E., & Mukarramah. (2020). Pengaruh Inflasi dan Kurs terhadap Pertumbuhan Ekonomi Indonesia. *Jurnal Samudra Ekonomika*, *4*(1), 41–50.
- Zaknich, A., & Attikiouzel, Y. (1997). Modified probabilistic neural network signal processor for nonlinear signals. *International Conference on Digital Signal Processing, DSP*, *1*, 291–294.

LAMPIRAN

Lampiran 1. Data harga terakhir Indeks Saham Syariah Indonesia dan Kurs

Tanggal	Terakhir	Kurs Jual	Kurs Beli
3-Jan-22	190.76	14349.39	14206.61
4-Jan-22	191.21	14341.35	14198.65
5-Jan-22	189.36	14381.55	14238.45
6-Jan-22	188.80	14436.83	14293.18
7-Jan-22	190.04	14467.98	14324.02
10-Jan-22	188.97	14431.80	14288.20
11-Jan-22	186.65	14394.62	14251.39
12-Jan-22	187.19	14370.50	14227.51
13-Jan-22	187.51	14373.51	14230.49
14-Jan-22	188.03	14382.56	14239.45
17-Jan-22	186.25	14381.55	14238.45
18-Jan-22	185.35	14394.62	14251.39
19-Jan-22	185.41	14396.63	14253.38
20-Jan-22	186.66	14441.85	14298.15
21-Jan-22	189.77	14425.77	14282.23
24-Jan-22	188.21	14418.74	14275.27
25-Jan-22	186.45	14398.64	14255.37
26-Jan-22	188.31	14429.79	14286.21
27-Jan-22	187.57	14417.73	14274.27
28-Jan-22	188.36	14456.93	14313.08
31-Jan-22	189.12	14452.91	14309.10
2-Feb-22	190.85	14463.96	14320.04
3-Feb-22	190.34	14418.74	14275.27
4-Feb-22	192.23	14452.91	14309.10
7-Feb-22	194.32	14447.88	14304.12

Tanggal	Terakhir	Kurs Jual	Kurs Beli
8-Feb-22	192.71	14476.02	14331.98
9-Feb-22	193.56	14456.93	14313.08
10-Feb-22	194.84	14437.83	14294.17
11-Feb-22	193.77	14415.72	14272.28
14-Feb-22	191.47	14430.80	14287.21
15-Feb-22	192.63	14409.69	14266.31
16-Feb-22	193.47	14363.46	14220.54
17-Feb-22	192.97	14349.39	14206.61
18-Feb-22	194.44	14372.51	14229.50
21-Feb-22	194.28	14410.70	14267.31
22-Feb-22	192.91	14400.65	14257.36
23-Feb-22	193.88	14433.81	14290.19
24-Feb-22	190.97	14426.78	14283.23
25-Feb-22	192.32	14442.86	14299.15
1-Mar-22	193.50	14440.85	14297.16
2-Mar-22	192.44	14421.75	14278.25
3-Mar-22	195.13	14444.87	14301.14
7-Mar-22	195.29	14454.92	14311.09
8-Mar-22	192.63	14483.06	14338.95
9-Mar-22	193.28	14465.97	14322.03
10-Mar-22	195.16	14442.86	14299.15
11-Mar-22	196.15	14369.49	14226.51
14-Mar-22	195.60	14377.53	14234.47
15-Mar-22	192.93	14399.64	14256.36
16-Mar-22	194.65	14392.61	14249.40
17-Mar-22	194.57	14382.56	14239.45
18-Mar-22	194.98	14361.45	14218.55
21-Mar-22	195.20	14411.70	14268.30
22-Mar-22	197.40	14412.71	14269.30
23-Mar-22	197.80	14429.79	14286.21

Tanggal	Terakhir	Kurs Jual	Kurs Beli
24-Mar-22	199.43	14422.76	14279.25
25-Mar-22	197.88	14432.81	14289.20
28-Mar-22	199.42	14412.71	14269.30
29-Mar-22	198.45	14431.80	14288.20
30-Mar-22	199.71	14435.82	14292.18
31-Mar-22	199.91	14420.75	14277.26
1-Apr-22	200.27	14428.79	14285.22
4-Apr-22	202.23	14435.82	14292.18
5-Apr-22	203.65	14433.81	14290.19
6-Apr-22	203.55	14419.74	14276.26
7-Apr-22	203.89	14435.82	14292.18
8-Apr-22	206.46	14430.80	14287.21
11-Apr-22	203.59	14436.83	14293.18
12-Apr-22	203.50	14441.85	14298.15
13-Apr-22	205.56	14435.82	14292.18
14-Apr-22	205.48	14430.80	14287.21
18-Apr-22	206.72	14420.75	14277.26
19-Apr-22	206.39	14427.78	14284.22
20-Apr-22	205.99	14418.74	14275.27
21-Apr-22	206.51	14422.76	14279.25
22-Apr-22	204.61	14419.74	14276.26
25-Apr-22	204.01	14432.81	14289.20
26-Apr-22	205.21	14524.26	14379.74
27-Apr-22	206.34	14484.06	14339.94
28-Apr-22	208.18	14490.09	14345.91
9-May-22	202.33	14552.40	14407.60
10-May-22	201.50	14606.67	14461.33
11-May-22	203.69	14618.73	14473.27
12-May-22	197.91	14618.73	14473.27
13-May-22	199.90	14657.93	14512.08

Tanggal	Terakhir	Kurs Jual	Kurs Beli
17-May-22	200.75	14692.10	14545.91
18-May-22	201.83	14724.26	14577.75
19-May-22	199.90	14755.41	14608.59
20-May-22	202.77	14804.66	14657.35
23-May-22	201.64	14734.31	14587.70
24-May-22	203.22	14738.33	14591.68
25-May-22	202.34	14726.27	14579.74
27-May-22	205.19	14718.23	14571.78
30-May-22	206.09	14650.89	14505.11
31-May-22	209.07	14616.72	14471.28
2-Jun-22	208.72	14664.96	14519.04
3-Jun-22	209.31	14598.63	14453.37
6-Jun-22	208.76	14503.16	14358.85
7-Jun-22	208.36	14534.31	14389.69
8-Jun-22	208.27	14536.32	14391.68
9-Jun-22	207.45	14549.39	14404.62
10-Jun-22	205.80	14627.78	14482.23
13-Jun-22	201.60	14641.85	14496.16
14-Jun-22	202.65	14745.36	14598.64
15-Jun-22	200.58	14802.65	14655.36
16-Jun-22	202.57	14819.73	14672.27
17-Jun-22	200.27	14814.71	14667.30
20-Jun-22	200.38	14902.14	14753.86
21-Jun-22	203.12	14910.18	14761.82
22-Jun-22	201.66	14878.02	14729.98
23-Jun-22	202.27	14934.30	14785.70
24-Jun-22	203.53	14909.18	14760.83
27-Jun-22	203.30	14920.23	14771.77
28-Jun-22	203.11	14876.01	14727.99
29-Jun-22	201.89	14911.19	14762.82

Tanggal	Terakhir	Kurs Jual	Kurs Beli
30-Jun-22	200.39	14922.24	14773.76
1-Jul-22	197.14	14956.41	14807.59
4-Jul-22	194.17	15030.78	14881.22
5-Jul-22	196.99	15034.80	14885.20
6-Jul-22	194.89	15064.95	14915.05
7-Jul-22	195.51	15090.08	14939.93
8-Jul-22	197.07	15060.93	14911.07
11-Jul-22	197.78	15055.91	14906.10
12-Jul-22	198.38	15043.84	14894.16
13-Jul-22	197.30	15067.97	14918.03
14-Jul-22	198.57	15059.92	14910.08
15-Jul-22	197.33	15074.00	14924.00
18-Jul-22	197.83	15074.00	14924.00
19-Jul-22	201.49	15060.93	14911.07
20-Jul-22	203.43	15066.96	14917.04
21-Jul-22	203.45	15058.92	14909.08
22-Jul-22	204.77	15092.08	14941.92
25-Jul-22	204.55	15099.12	14948.88
26-Jul-22	203.83	15066.96	14917.04
27-Jul-22	204.94	15058.92	14909.08
28-Jul-22	206.52	15095.10	14944.90
29-Jul-22	205.84	15032.79	14883.21
1-Aug-22	207.34	14934.30	14785.70
2-Aug-22	206.65	14948.37	14799.63
3-Aug-22	207.92	14962.44	14813.56
4-Aug-22	207.97	14991.58	14842.42
5-Aug-22	208.57	15003.65	14854.35
8-Aug-22	209.64	14978.52	14829.48
9-Aug-22	209.42	14989.58	14840.42
10-Aug-22	209.06	14936.31	14787.69

Tanggal	Terakhir	Kurs Jual	Kurs Beli
11-Aug-22	210.57	14949.38	14800.63
12-Aug-22	210.01	14873.00	14725.00
15-Aug-22	208.48	14761.44	14614.56
16-Aug-22	207.56	14800.64	14653.36
18-Aug-22	208.38	14840.83	14693.17
19-Aug-22	208.48	14896.11	14747.89
22-Aug-22	206.26	14932.29	14783.71
23-Aug-22	208.55	14956.41	14807.59
24-Aug-22	209.62	14967.47	14818.53
25-Aug-22	208.51	14925.25	14776.75
26-Aug-22	207.98	14901.14	14752.86
29-Aug-22	207.82	14888.07	14739.93
30-Aug-22	208.37	14961.43	14812.57
31-Aug-22	208.63	14949.38	14800.63
1-Sep-22	208.34	14927.26	14778.74
2-Sep-22	209.46	14958.42	14809.58
5-Sep-22	210.63	14974.50	14825.50
6-Sep-22	211.51	14994.60	14845.40
7-Sep-22	210.63	14959.42	14810.58
8-Sep-22	211.23	15001.64	14852.36
9-Sep-22	211.47	14979.52	14830.48
12-Sep-22	212.33	14920.23	14771.77
13-Sep-22	213.03	14913.19	14764.81
14-Sep-22	211.86	14935.31	14786.69
15-Sep-22	212.27	14997.61	14848.39
16-Sep-22	211.13	14973.50	14824.50
19-Sep-22	210.76	15013.69	14864.31
20-Sep-22	210.06	15054.90	14905.10
21-Sep-22	209.54	15049.88	14900.13
22-Sep-22	211.25	15086.06	14935.94

Tanggal	Terakhir	Kurs Jual	Kurs Beli
23-Sep-22	210.09	15108.17	14957.83
26-Sep-22	207.50	15110.17	14959.83
27-Sep-22	207.25	15194.59	15043.41
28-Sep-22	205.22	15230.77	15079.23
29-Sep-22	204.40	15319.22	15166.78
30-Sep-22	204.10	15323.24	15170.76
3-Oct-22	203.74	15308.16	15155.84
4-Oct-22	205.78	15369.47	15216.53
5-Oct-22	206.52	15352.38	15199.62
6-Oct-22	206.37	15271.98	15120.02
7-Oct-22	205.88	15272.99	15121.01
10-Oct-22	204.60	15322.23	15169.77
11-Oct-22	203.91	15375.50	15222.50
12-Oct-22	203.63	15438.81	15285.19
13-Oct-22	202.95	15449.86	15296.14
14-Oct-22	201.77	15433.78	15280.22
17-Oct-22	201.88	15466.95	15313.05
18-Oct-22	201.18	15557.40	15402.60
19-Oct-22	202.46	15546.34	15391.66
20-Oct-22	205.45	15568.45	15413.55
21-Oct-22	205.16	15656.90	15501.10
24-Oct-22	205.69	15688.05	15531.95
25-Oct-22	204.94	15667.95	15512.05
26-Oct-22	207.10	15694.08	15537.92
27-Oct-22	207.78	15673.98	15518.02
28-Oct-22	206.81	15650.86	15495.14
31-Oct-22	207.73	15619.71	15464.29
1-Nov-22	206.66	15673.98	15518.02
2-Nov-22	206.23	15725.24	15568.76
3-Nov-22	206.21	15730.26	15573.74

Tanggal	Terakhir	Kurs Jual	Kurs Beli
4-Nov-22	207.41	15759.41	15602.59
7-Nov-22	209.29	15814.68	15657.32
8-Nov-22	207.99	15770.46	15613.54
9-Nov-22	207.58	15762.42	15605.58
10-Nov-22	205.13	15732.27	15575.73
11-Nov-22	207.07	15779.50	15622.50
14-Nov-22	206.05	15570.47	15415.53
15-Nov-22	206.45	15576.50	15421.50
16-Nov-22	205.49	15641.82	15486.18
17-Nov-22	205.97	15688.05	15531.95
18-Nov-22	206.58	15765.43	15608.57
21-Nov-22	208.06	15770.46	15613.54
22-Nov-22	207.44	15785.53	15628.47
23-Nov-22	208.37	15794.58	15637.42
24-Nov-22	209.03	15778.50	15621.50
25-Nov-22	208.22	15725.24	15568.76
28-Nov-22	207.30	15746.34	15589.66
29-Nov-22	208.27	15807.65	15650.35
30-Nov-22	209.01	15815.68	15658.32
1-Dec-22	208.92	15820.71	15663.29
2-Dec-22	211.14	15695.08	15538.92
5-Dec-22	211.87	15506.15	15351.85
6-Dec-22	209.90	15486.05	15331.95
7-Dec-22	210.63	15653.88	15498.12
8-Dec-22	210.50	15697.09	15540.91
9-Dec-22	206.79	15702.12	15545.88
12-Dec-22	207.94	15664.93	15509.07
13-Dec-22	208.06	15720.21	15563.79
14-Dec-22	208.78	15739.31	15582.69
15-Dec-22	207.47	15697.09	15540.91

Tanggal	Terakhir	Kurs Jual	Kurs Beli
16-Dec-22	209.95	15708.15	15551.85
19-Dec-22	209.55	15695.08	15538.92
20-Dec-22	211.54	15699.10	15542.90
21-Dec-22	215.02	15686.04	15529.96
22-Dec-22	214.81	15679.00	15523.00
23-Dec-22	215.12	15671.97	15516.03
26-Dec-22	217.68	15683.02	15526.98
27-Dec-22	222.00	15714.18	15557.82
28-Dec-22	218.38	15737.30	15580.70
29-Dec-22	217.78	15781.51	15624.49
30-Dec-22	217.73	15809.66	15652.34
2-Jan-23	217.18	15669.96	15514.04
3-Jan-23	218.60	15649.86	15494.14
4-Jan-23	215.76	15667.95	15512.05
5-Jan-23	210.75	15693.08	15536.92
6-Jan-23	212.57	15688.05	15531.95
9-Jan-23	212.74	15713.17	15556.83
10-Jan-23	212.62	15651.87	15496.13
11-Jan-23	212.66	15666.94	15511.06
12-Jan-23	211.96	15604.64	15449.36
13-Jan-23	212.14	15442.83	15289.17
16-Jan-23	212.85	15252.89	15101.11
17-Jan-23	213.35	15094.09	14943.91
18-Jan-23	213.82	15229.77	15078.23
19-Jan-23	215.14	15212.68	15061.32
20-Jan-23	217.57	15188.57	15037.43
24-Jan-23	216.28	15196.60	15045.40
25-Jan-23	215.15	15004.65	14855.35
26-Jan-23	213.79	15032.79	14883.21
27-Jan-23	213.82	15038.82	14889.18

Tanggal	Terakhir	Kurs Jual	Kurs Beli
30-Jan-23	213.79	15052.89	14903.11
31-Jan-23	212.64	15053.90	14904.10
1-Feb-23	213.19	15066.96	14917.04
2-Feb-23	214.18	15065.95	14916.05
3-Feb-23	212.73	14942.34	14793.66
6-Feb-23	211.75	14972.49	14823.51
7-Feb-23	213.78	15130.27	14979.73
8-Feb-23	213.98	15214.69	15063.31
9-Feb-23	212.68	15197.61	15046.39
10-Feb-23	212.24	15195.60	15044.40
13-Feb-23	212.26	15215.70	15064.30
14-Feb-23	213.43	15292.08	15139.92
15-Feb-23	213.01	15243.84	15092.16
16-Feb-23	212.49	15269.97	15118.03
17-Feb-23	211.62	15251.88	15100.12
20-Feb-23	211.99	15275.00	15123.00
21-Feb-23	212.00	15243.84	15092.16
22-Feb-23	210.67	15254.90	15103.10
23-Feb-23	212.21	15294.09	15141.91
24-Feb-23	212.68	15262.93	15111.07
27-Feb-23	211.83	15292.08	15139.92
28-Feb-23	212.27	15350.37	15197.63
1-Mar-23	211.48	15316.20	15163.80
2-Mar-23	211.16	15326.25	15173.75
3-Mar-23	210.61	15349.36	15196.64
6-Mar-23	209.75	15382.53	15229.47
7-Mar-23	207.87	15377.50	15224.50
8-Mar-23	207.50	15435.80	15282.20
9-Mar-23	208.04	15528.25	15373.75
10-Mar-23	207.69	15515.19	15360.81

Tanggal	Terakhir	Kurs Jual	Kurs Beli
13-Mar-23	208.56	15545.34	15390.66
14-Mar-23	205.25	15450.87	15297.13
15-Mar-23	204.27	15456.90	15303.10
16-Mar-23	201.95	15441.83	15288.17
17-Mar-23	205.96	15495.09	15340.91
20-Mar-23	203.92	15440.82	15287.18
21-Mar-23	205.53	15448.86	15295.14
24-Mar-23	206.87	15425.75	15272.25
27-Mar-23	206.72	15264.94	15113.06
28-Mar-23	209.24	15249.87	15098.13
29-Mar-23	211.71	15163.44	15012.56
30-Mar-23	211.51	15169.47	15018.53
31-Mar-23	211.27	15137.31	14986.69

Lampiran 2. Data inflasi

Periode	Inflasi
Januari 2022	2.18%
Februari 2022	2.06%
Maret 2022	2.64%
April 2022	3.47%
Mei 2022	3.55%
Juni 2022	4.35%
Juli 2022	4.94%
Agustus 2022	4.69%
September 2022	5.95%
Oktober 2022	5.71%
November 2022	5.42%
Desember 2022	5.51%
Januari 2023	5.28%
Februari 2023	5.47%
Maret 2023	4.97%

Lampiran 3. *Syntax* Python

```

import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from sklearn import preprocessing
from sklearn.model_selection import train_test_split
from sklearn.metrics import mean_squared_error, mean_absolute_error
from math import sqrt
from statsmodels.graphics.tsaplots import plot_pacf, plot_acf
from statsmodels.tsa.stattools import pacf
from scipy.stats import spearmanr
from neupy import algorithms
from sklearn.preprocessing import MinMaxScaler

#data
data = pd.read_csv('data.csv')
data = data.set_index('Tanggal')
data

pd.to_datetime(data.index)
data.info()

desc = data.describe()
desc

#plot ISSI
plt.figure(figsize=(12,8))
data['Terakhir'].plot()
plt.ylabel('Harga Terakhir')

#plot kurs jual
plt.figure(figsize=(12,8))
data['Kurs Jual'].plot()
plt.ylabel('Kurs Jual')

#plot kurs beli
plt.figure(figsize=(12,8))
data['Kurs Beli'].plot()
plt.ylabel('Kurs Beli')

```



```

#plot inflasi
dinflasi = pd.read_csv('Inflasi.csv')
dinflasi = dinflasi.set_index('Periode')
plt.figure(figsize=(12,8))
dinflasi['Data Inflasi'].plot()
plt.ylabel('Inflasi')

#scatterplot kurs jual
plt.figure(figsize=(12,8))
plt.scatter(data['Kurs Jual'],data['Terakhir'])
plt.xlabel('Kurs Jual')
plt.ylabel('Harga Terakhir')

#scatterplot kurs beli
plt.figure(figsize=(12,8))
plt.scatter(data['Kurs Beli'], data['Terakhir'])
plt.xlabel('Kurs Beli')
plt.ylabel('Harga Terakhir')

#scatterplot inflasi
plt.figure(figsize=(12,8))
plt.scatter(data['Inflasi'], data['Terakhir'])
plt.xlabel('Inflasi')
plt.ylabel('Harga Terakhir')

#korelasi
k1 = spearmanr(data['Terakhir'], data['Kurs Jual'])
k2 = spearmanr(data['Terakhir'], data['Kurs Beli'])
k3 = spearmanr(data['Terakhir'], data['Inflasi'])
corr = pd.DataFrame([k1,k2,k3], columns = [['Koefisien Korelasi','P-Value']])
corr = corr.rename(index={0: 'Kurs Jual', 1:'Kurs Beli', 2:'Inflasi'})
corr

#pacf
vpacf=pacf(data['Terakhir'])
vpacf
plt.figure()
plot_pacf(data['Terakhir'])
plt.show()

```

```

#data fix
data['X'] = data['Terakhir'].shift(+1)
data = data.dropna()
data

inputX = data[['X', 'Kurs Jual', 'Kurs Beli', 'Inflasi']].values
inputY = data['Terakhir'].values

#splitting data
xtrain, xtest, ytrain, ytest = train_test_split(
    inputX, inputY, test_size = 0.2,
    random_state = 0, shuffle=False)
xtrain = pd.DataFrame(xtrain, columns=['X', 'Kurs Jual', 'Kurs Beli', 'Inflasi'])
ytrain = pd.DataFrame(ytrain, columns=['Aktual'])
xtest = pd.DataFrame(xtest, columns=['X', 'Kurs Jual', 'Kurs Beli', 'Inflasi'])
ytest = pd.DataFrame(ytest, columns=['Aktual'])

ytest.info()
ytrain.info()

#normalisasi Y
scaler1 = MinMaxScaler()
scaler1.fit(ytrain)

ytrain = scaler1.transform(ytrain)
ytest = scaler1.transform(ytest)

#normalisasi X
scaler2 = MinMaxScaler()
scaler2.fit(xtrain)

xtrain = scaler2.transform(xtrain)
xtest = scaler2.transform(xtest)

xtrain = pd.DataFrame(xtrain, columns=['X', 'nJual', 'nBeli', 'nInflasi'])
ytrain = pd.DataFrame(ytrain, columns=['Aktual'])
xtest = pd.DataFrame(xtest, columns=['X', 'nJual', 'nBeli', 'nInflasi'])
ytest1 = pd.DataFrame(ytest, columns=['Aktual'])
ytest = np.array(ytest)

```

```
#Input Data Masa Lalu
##GRNN
pred105 = algorithms.GRNN(std = 0.05, verbose=False)
pred105.train(xtrain['X'], ytrain['Aktual'])

pred11 = algorithms.GRNN(std = 0.1, verbose=False)
pred11.train(xtrain['X'], ytrain['Aktual'])

pred115 = algorithms.GRNN(std = 0.15, verbose=False)
pred115.train(xtrain['X'], ytrain['Aktual'])

pred12 = algorithms.GRNN(std = 0.2, verbose=False)
pred12.train(xtrain['X'], ytrain['Aktual'])

pred125 = algorithms.GRNN(std = 0.25, verbose=False)
pred125.train(xtrain['X'], ytrain['Aktual'])

pred13 = algorithms.GRNN(std = 0.3, verbose=False)
pred13.train(xtrain['X'], ytrain['Aktual'])

pred135 = algorithms.GRNN(std = 0.35, verbose=False)
pred135.train(xtrain['X'], ytrain['Aktual'])

pred14 = algorithms.GRNN(std = 0.4, verbose=False)
pred14.train(xtrain['X'], ytrain['Aktual'])

pred145 = algorithms.GRNN(std = 0.45, verbose=False)
pred145.train(xtrain['X'], ytrain['Aktual'])

pred15 = algorithms.GRNN(std = 0.5, verbose=False)
pred15.train(xtrain['X'], ytrain['Aktual'])

##prediksi
ypred05 = pred105.predict(xtest['X'])
ypred1 = pred11.predict(xtest['X'])
ypred15 = pred115.predict(xtest['X'])
ypred2 = pred12.predict(xtest['X'])
ypred25 = pred125.predict(xtest['X'])
ypred3 = pred13.predict(xtest['X'])
```

```

ypred35 = pred135.predict(xtest['X'])
ypred4 = pred14.predict(xtest['X'])
ypred45 = pred145.predict(xtest['X'])
ypred5 = pred15.predict(xtest['X'])

yaktual = scaler1.inverse_transform(ytest)
ypred05 = scaler1.inverse_transform(ypred05)
ypred1 = scaler1.inverse_transform(ypred1)
ypred15 = scaler1.inverse_transform(ypred15)
ypred2 = scaler1.inverse_transform(ypred2)
ypred25 = scaler1.inverse_transform(ypred25)
ypred3 = scaler1.inverse_transform(ypred3)
ypred35 = scaler1.inverse_transform(ypred35)
ypred4 = scaler1.inverse_transform(ypred4)
ypred45 = scaler1.inverse_transform(ypred45)
ypred5 = scaler1.inverse_transform(ypred5)

##pengujian
mae105 = mean_absolute_error(yaktual, ypred05)
rmse105 = sqrt(mean_squared_error(yaktual, ypred05))

mae11 = mean_absolute_error(yaktual, ypred1)
rmse11 = sqrt(mean_squared_error(yaktual, ypred1))

mae115 = mean_absolute_error(yaktual, ypred15)
rmse115 = sqrt(mean_squared_error(yaktual, ypred15))

mae12 = mean_absolute_error(yaktual, ypred2)
rmse12 = sqrt(mean_squared_error(yaktual, ypred2))

mae125 = mean_absolute_error(yaktual, ypred25)
rmse125 = sqrt(mean_squared_error(yaktual, ypred25))

mae13 = mean_absolute_error(yaktual, ypred3)
rmse13 = sqrt(mean_squared_error(yaktual, ypred3))

mae135 = mean_absolute_error(yaktual, ypred35)
rmse135 = sqrt(mean_squared_error(yaktual, ypred35))

mae14 = mean_absolute_error(yaktual, ypred4)

```

```

rmse14 = sqrt(mean_squared_error(yaktual, ypred4))

mae145 = mean_absolute_error(yaktual, ypred45)
rmse145 = sqrt(mean_squared_error(yaktual, ypred45))

mae15 = mean_absolute_error(yaktual, ypred5)
rmse15 = sqrt(mean_squared_error(yaktual, ypred5))

uji105 = pd.DataFrame([mae105, rmse105], columns=['0.05'])
uji11 = pd.DataFrame([mae11, rmse11], columns=['0.1'])
uji115 = pd.DataFrame([mae115, rmse115], columns=['0.15'])
uji12 = pd.DataFrame([mae12, rmse12], columns=['0.2'])
uji125 = pd.DataFrame([mae125, rmse125], columns=['0.25'])
uji13 = pd.DataFrame([mae13, rmse13], columns=['0.3'])
uji135 = pd.DataFrame([mae135, rmse135], columns=['0.35'])
uji14 = pd.DataFrame([mae14, rmse14], columns=['0.4'])
uji145 = pd.DataFrame([mae145, rmse145], columns=['0.45'])
uji15 = pd.DataFrame([mae15, rmse15], columns=['0.5'])

uji1 = pd.concat([uji105, uji11, uji115, uji12, uji125, uji13, uji135, uji14, uji145,
uji15], axis=1)
uji1 = uji1.rename(index={0:'MAE', 1:'RMSE'})
uji1

#grafik spread
ujii1 = uji1.transpose()
ujii1.plot()
plt.xlabel('Spread')
plt.ylabel('Nilai')

##hasil prediksi
yaktual = pd.DataFrame(yaktual, columns=['Aktual'])
ypred = pd.DataFrame(ypred05, columns=['Prediksi'])
df1 = pd.concat([yaktual,ypred], axis=1)
df1

##grafik
df1.plot()
plt.xlabel('Index')
plt.ylabel('Harga Terakhir')

```

```

#input makroekonomi
##GRNN
pred205 = algorithms.GRNN(std = 0.05, verbose=False)
pred205.train(xtrain[['X','nJual','nBeli','nInflasi']], ytrain['Aktual'])

pred21 = algorithms.GRNN(std = 0.1, verbose=False)
pred21.train(xtrain[['X','nJual','nBeli','nInflasi']], ytrain['Aktual'])

pred215 = algorithms.GRNN(std = 0.15, verbose=False)
pred215.train(xtrain[['X','nJual','nBeli','nInflasi']], ytrain['Aktual'])

pred22 = algorithms.GRNN(std = 0.2, verbose=False)
pred22.train(xtrain[['X','nJual','nBeli','nInflasi']], ytrain['Aktual'])

pred225 = algorithms.GRNN(std = 0.25, verbose=False)
pred225.train(xtrain[['X','nJual','nBeli','nInflasi']], ytrain['Aktual'])

pred23 = algorithms.GRNN(std = 0.3, verbose=False)
pred23.train(xtrain[['X','nJual','nBeli','nInflasi']], ytrain['Aktual'])

pred235 = algorithms.GRNN(std = 0.35, verbose=False)
pred235.train(xtrain[['X','nJual','nBeli','nInflasi']], ytrain['Aktual'])

pred24 = algorithms.GRNN(std = 0.4, verbose=False)
pred24.train(xtrain[['X','nJual','nBeli','nInflasi']], ytrain['Aktual'])

pred245 = algorithms.GRNN(std = 0.45, verbose=False)
pred245.train(xtrain[['X','nJual','nBeli','nInflasi']], ytrain['Aktual'])

pred25 = algorithms.GRNN(std = 0.5, verbose=False)
pred25.train(xtrain[['X','nJual','nBeli','nInflasi']], ytrain['Aktual'])

#prediksi
y_pred05 = pred205.predict(xtest[['X','nJual','nBeli','nInflasi']])
y_pred1 = pred21.predict(xtest[['X','nJual','nBeli','nInflasi']])
y_pred15 = pred215.predict(xtest[['X','nJual','nBeli','nInflasi']])
y_pred2 = pred22.predict(xtest[['X','nJual','nBeli','nInflasi']])
y_pred25 = pred225.predict(xtest[['X','nJual','nBeli','nInflasi']])
y_pred3 = pred23.predict(xtest[['X','nJual','nBeli','nInflasi']])

```

```

y_pred35 = pred235.predict(xtest[['X','nJual','nBeli','nInflasi']])
y_pred4 = pred24.predict(xtest[['X','nJual','nBeli','nInflasi']])
y_pred45 = pred245.predict(xtest[['X','nJual','nBeli','nInflasi']])
y_pred5 = pred25.predict(xtest[['X','nJual','nBeli','nInflasi']])

```

```

y_aktual = scaler1.inverse_transform(ytest)
y_pred05 = scaler1.inverse_transform(y_pred05)
y_pred1 = scaler1.inverse_transform(y_pred1)
y_pred15 = scaler1.inverse_transform(y_pred15)
y_pred2 = scaler1.inverse_transform(y_pred2)
y_pred25 = scaler1.inverse_transform(y_pred25)
y_pred3 = scaler1.inverse_transform(y_pred3)
y_pred35 = scaler1.inverse_transform(y_pred35)
y_pred4 = scaler1.inverse_transform(y_pred4)
y_pred45 = scaler1.inverse_transform(y_pred45)
y_pred5 = scaler1.inverse_transform(y_pred5)

```

```

##pengujian

```

```

mae205 = mean_absolute_error(y_aktual, y_pred05)
rmse205 = sqrt(mean_squared_error(y_aktual, y_pred05))

```

```

mae21 = mean_absolute_error(y_aktual, y_pred1)
rmse21 = sqrt(mean_squared_error(y_aktual, y_pred1))

```

```

mae215 = mean_absolute_error(y_aktual, y_pred15)
rmse215 = sqrt(mean_squared_error(y_aktual, y_pred15))

```

```

mae22 = mean_absolute_error(y_aktual, y_pred2)
rmse22 = sqrt(mean_squared_error(y_aktual, y_pred2))

```

```

mae225 = mean_absolute_error(y_aktual, y_pred25)
rmse225 = sqrt(mean_squared_error(y_aktual, y_pred25))

```

```

mae23 = mean_absolute_error(y_aktual, y_pred3)
rmse23 = sqrt(mean_squared_error(y_aktual, y_pred3))

```

```

mae235 = mean_absolute_error(y_aktual, y_pred35)
rmse235 = sqrt(mean_squared_error(y_aktual, y_pred35))

```

```

mae24 = mean_absolute_error(y_aktual, y_pred4)

```

```

rmse24 = sqrt(mean_squared_error(y_aktual, y_pred4))

mae245 = mean_absolute_error(y_aktual, y_pred45)
rmse245 = sqrt(mean_squared_error(y_aktual, y_pred45))

mae25 = mean_absolute_error(y_aktual, y_pred5)
rmse25 = sqrt(mean_squared_error(y_aktual, y_pred5))

uji205 = pd.DataFrame([mae205, rmse205], columns=['0.05'])
uji21 = pd.DataFrame([mae21, rmse21], columns=['0.1'])
uji215 = pd.DataFrame([mae215, rmse215], columns=['0.15'])
uji22 = pd.DataFrame([mae22, rmse22], columns=['0.2'])
uji225 = pd.DataFrame([mae225, rmse225], columns=['0.25'])
uji23 = pd.DataFrame([mae23, rmse23], columns=['0.3'])
uji235 = pd.DataFrame([mae235, rmse235], columns=['0.35'])
uji24 = pd.DataFrame([mae24, rmse24], columns=['0.4'])
uji245 = pd.DataFrame([mae245, rmse245], columns=['0.45'])
uji25 = pd.DataFrame([mae25, rmse25], columns=['0.5'])

uji2 = pd.concat([uji205, uji21, uji215, uji22, uji225, uji23, uji235, uji24, uji245,
uji25], axis=1)
uji2 = uji2.rename(index={0:'MAE', 1:'RMSE'})
uji2

#grafik spread
ujii2 = uji2.transpose()
ujii2.plot()
plt.xlabel('Spread')
plt.ylabel('Nilai')

##hasil prediksi
y_aktual = pd.DataFrame(y_aktual, columns=['Aktual'])
y_pred = pd.DataFrame(y_pred05, columns=['Prediksi 2'])
df2 = pd.concat([y_aktual,y_pred], axis=1)
df2

#grafik
df2.plot()
plt.xlabel('Index')
plt.ylabel('Harga Terakhir')

```



```
#perbandingan aktual dan prediksi
df3 = pd.concat([yaktual,ypred,y_pred], axis=1)
df3
df3.plot()

#perbandingan pengujian
uji_1 = pd.DataFrame([mae105, rmse105], columns=['Input 1'])
uji_2 = pd.DataFrame([mae205, rmse205], columns=['Input 2'])
uji = pd.concat([uji_1, uji_2], axis=1)
uji = uji.rename(index={0:'MAE', 1:'RMSE'})
uji
```

Lampiran 4. Hasil normalisasi data pelatihan

Tanggal	Terakhir	Masa Lalu	Kurs Jual	Kurs Beli	Inflasi
4-Jan-22	0.15989	0.14761	0.00000	0.00000	0.03085
5-Jan-22	0.10941	0.15989	0.02717	0.02717	0.03085
6-Jan-22	0.09413	0.10941	0.06454	0.06454	0.03085
7-Jan-22	0.12797	0.09413	0.08560	0.08560	0.03085
10-Jan-22	0.09877	0.12797	0.06114	0.06114	0.03085
...
26-Dec-22	0.88213	0.81228	0.90693	0.90693	0.88689
27-Dec-22	1.00000	0.88213	0.92799	0.92799	0.88689
28-Dec-22	0.90123	1.00000	0.94362	0.94361	0.88689
29-Dec-22	0.88486	0.90123	0.97350	0.97351	0.88689
30-Dec-22	0.88349	0.88486	0.99253	0.99252	0.88689

Lampiran 5. Hasil normalisasi data pengujian

Tanggal	Terakhir	Masa Lalu	Kurs Jual	Kurs Beli	Inflasi
2-Jan-23	0.868486	0.883492	0.898098	0.898098	0.827763
3-Jan-23	0.907231	0.868486	0.884511	0.884511	0.827763
4-Jan-23	0.829741	0.907231	0.896739	0.896739	0.827763
5-Jan-23	0.693042	0.829741	0.913726	0.913719	0.827763
6-Jan-23	0.742701	0.693042	0.910326	0.910326	0.827763
...
27-Mar-23	0.583083	0.587176	0.624317	0.624324	0.748072
28-Mar-23	0.651842	0.583083	0.614130	0.614130	0.748072
29-Mar-23	0.719236	0.651842	0.555707	0.555707	0.748072
30-Mar-23	0.713779	0.719236	0.559783	0.559783	0.748072
31-Mar-23	0.707231	0.713779	0.538043	0.538043	0.748072

Lampiran 6. Hasil prediksi data *testing input* data masa lalu

Tanggal	Aktual	Prediksi	Prediksi 2
2-Jan-23	217.18	218.90	219.65
3-Jan-23	218.60	218.58	217.62
4-Jan-23	215.76	218.96	221.04
5-Jan-23	210.75	216.48	216.63
6-Jan-23	212.57	209.94	209.94
9-Jan-23	212.74	211.38	212.16
10-Jan-23	212.62	211.53	213.67
11-Jan-23	212.66	211.43	213.19
12-Jan-23	211.96	211.46	213.45
13-Jan-23	212.14	210.91	210.44
16-Jan-23	212.85	211.04	206.18
17-Jan-23	213.35	211.64	209.89
18-Jan-23	213.82	212.24	208.42
19-Jan-23	215.14	213.04	209.72
20-Jan-23	217.57	215.52	209.97
24-Jan-23	216.28	218.84	210.07
25-Jan-23	215.15	217.34	211.64
26-Jan-23	213.79	215.54	211.47
27-Jan-23	213.82	212.99	211.13
30-Jan-23	213.79	213.04	210.94
31-Jan-23	212.64	212.99	210.91
1-Feb-23	213.19	211.44	210.42
2-Feb-23	214.18	212.02	210.56
3-Feb-23	212.73	213.77	211.89
6-Feb-23	211.75	211.52	211.51
7-Feb-23	213.78	210.75	209.48
8-Feb-23	213.98	212.97	209.77

Tanggal	Aktual	Prediksi	Prediksi 2
9-Feb-23	212.68	213.36	209.83
10-Feb-23	212.24	211.48	209.50
13-Feb-23	212.26	211.12	208.71
14-Feb-23	213.43	211.13	206.31
15-Feb-23	213.01	212.36	208.94
16-Feb-23	212.49	211.81	206.40
17-Feb-23	211.62	211.32	206.52
20-Feb-23	211.99	210.65	206.12
21-Feb-23	212.00	210.93	206.42
22-Feb-23	210.67	210.94	206.23
23-Feb-23	212.21	209.87	206.04
24-Feb-23	212.68	211.10	206.20
27-Feb-23	211.83	211.48	206.80
28-Feb-23	212.27	210.81	210.03
1-Mar-23	211.48	211.14	209.99
2-Mar-23	211.16	210.54	210.03
3-Mar-23	210.61	210.28	210.13
6-Mar-23	209.75	209.82	210.33
7-Mar-23	207.87	209.08	210.42
8-Mar-23	207.50	207.71	208.23
9-Mar-23	208.04	207.46	206.18
10-Mar-23	207.69	207.83	206.24
13-Mar-23	208.56	207.59	206.17
14-Mar-23	205.25	208.19	209.50
15-Mar-23	204.27	205.63	206.22
16-Mar-23	201.95	204.55	205.37
17-Mar-23	205.96	202.53	205.41
20-Mar-23	203.92	206.29	206.17
21-Mar-23	205.53	204.16	205.42
24-Mar-23	206.87	205.91	205.65

Tanggal	Aktual	Prediksi	Prediksi 2
27-Mar-23	206.72	207.00	205.40
28-Mar-23	209.24	206.89	205.38
29-Mar-23	211.71	208.69	205.64
30-Mar-23	211.51	210.72	207.08
31-Mar-23	211.27	210.57	207.94

Keterangan:

Prediksi = hasil prediksi dengan input data masa lalu

Prediksi 2 = hasil prediksi dengan kurs jual, kurs beli, dan inflasi

Lampiran 7. Input prediksi dengan input faktor makroekonomi

Tanggal		Masa Lalu	Kurs Jual	Kurs Beli	Inflasi
3-Apr-23	Asli	211.27	15051.89	14902.11	0.0433
	Normalisasi	0.70723	0.48030	0.48030	0.58355
4-Apr-23	Asli	210.97	15064.95	14915.05	0.0433
	Normalisasi	0.69905	0.48913	0.48913	0.58355
5-Apr-23	Asli	211.72	14987.57	14838.43	0.0433
	Normalisasi	0.71951	0.43682	0.43682	0.58355
6-Apr-23	Asli	211.32	15007.67	14858.33	0.0433
	Normalisasi	0.70859	0.45041	0.45040	0.58355